비디오 클러스터링을 통한 위험 운전 습관 분석

김태욱[O], 주준경[*], 박규민[**], 신효승[*], 홍정희[*]
[*]연세대학교 소프트웨어학부,
[**]연세대학교 컴퓨터정보통신공학부,
[O]연세대학교 소프트웨어학부
e-mail: {jmhh10715, hyoseung8017, ellenhong}@yonsei.ac.kr[*],
gyugyuv2@yonsei.ac.kr[**], xodnr8436@yonsei.ac.kr[O]

Risky Driving Behavior Analysis using Video Clustering

Tae-Wook Kim[O], Jun-Kyung Ju[*], Gue-Min Park[**], Hyo-Seung Shin[*], Ellen J. Hong[*]
[*]Division of Software, Yonsei University,
[**]Dept of Computer & Telecommunications Engineering, Yonsei University,
[O]Division of Software, Yonsei University

● 요 약 ●

교통사고는 매년 인적 피해와 사회적 비용을 발생시킨다. 따라서 교통사고를 분석하고 예방하는 것은 매우 중요하다. 교통사고의 큰 원인 중 하나인 운전자 습관을 분석하기 위해, 본 논문은 딥러닝 모델을 대조 학습하고 클러스터링 기법을 통하여, 유사한 운전 습관을 지닌 운전자 집단을 형성하는 방법을 제안한다. 결과적으로 영상으로부터 6개의 운전자 집단을 형성하였고, 각 집단의 위험도를 산출하여 비교 분석하였다.

키워드: Video clustering, Contrastive learning, K-Means

I. Introduction

교통사고는 매년 인적 피해와 사회적 비용을 발생시키므로, 이를 분석하고 예방하는 것은 매우 중요하다. 최근 교통사고의 원인 중 운전 습관을 분석하고자, 운전자 특성[1]이나 차량 가속계 센서[2]를 사용한 분석 관련 연구가 진행되었으나, 운전 영상은 연구에 사용되지 않았다. 따라서 본 논문은 딥러닝 모델 기반의 대조 학습을 통해 비디오 클러스터링을 수행하여, 위험한 운전 습관을 분석하고자 한다.

II. Related works

최근 운전자의 인적 및 차량 특징[1]이나 가속계 센서[2] 데이터를 기반으로 K-Means와 같은 클러스터 기법을 통해 운전자 습관을 위험 정도에 따라 분류하는 연구가 진행되었다. 그러나 위 특징보다 상대적으로 운전자 습관에 대한 많은 정보를 가지는 운전 영상은 기존 클러스터링 기법으로 분석하기 어려움이 있어 연구에 거의 사용되지 않았다. 최근에는 ResNet3D 모델을 대조 학습하여, 유사한 영상에 대해 유사한 벡터를 산출할 수 있는 모델에 관한 연구가 진행되었다[3]. 위와 같은 방법을 활용하면, 운전 영상으로부터 유사성이 고려된 벡터를 추출하여 클러스터링을 수행할 수 있다.

III. The Proposed Scheme

본 논문에서는 딥러닝 모델 기반 대조 학습을 통해 유사한 운전 영상들을 모아 클러스터로 형성하고, 각 클러스터를 분석하고자 한다.

1. 데이터셋 구축

본 논문은 AIHUB에서 제공하는 교통사고 영상 데이터[4]를 기반으로 위험 운전 습관을 분석하고자 한다. 해당 데이터셋은 차대차, 차대보행자 등의 사고 대상과 직선도로, 횡단보도 등의 사고 장소 등으로 구분되는 21,895개 사고 영상과 라벨로 구성된다.

이 중 위험한 운전자 습관 분석을 위해, 차대차 사고 블랙박스 영상 중 자기 과실이 70% 이상인 영상만을 사용한다. 또한, 각 영상은 사고 시점 전후 5초를 포함하는데, 사고를 유발하는 운전 습관 분석을 위해 각 영상에서 0초부터 4초까지만 사용한다.

이후, 추출된 영상을 딥러닝 모델에 대조 학습하기 위해 각 영상으로부터 같은 시간 간격으로 16 프레임을 추출하고 영상 크기를 224x224로 조정한 뒤, 영상의 각 RGB 채널을 255로 나눠 정규화한다.

2. 비디오 대조 학습

기존의 비디오 대조 학습 연구[4]와 유사하게, 1절에서 구축한 N개의 영상에 대해서 각 영상에 서로 다른 가우시안 필터를 적용하여 2N개의 변조된 영상을 생성한다. 이후 딥러닝 모델에 2N개의 영상을 입력하여 모델로부터 영상에 대한 벡터를 얻는다. 이때, 딥러닝 모델은 3D Convolutional Layer와 DNN으로 구성하고, 입력된 비디오에 대해서 3차원 벡터를 산출하도록 한다. 마지막으로 같은 영상으로부터 변조된 벡터 간 유사도는 높고, 다른 영상으로부터 변조된 벡터 간 유사도는 낮은 방향으로 학습하기 위해, NT-Xent 손실 함수[5]를 사용하여 대조 학습을 진행한다.

3. 비디오 벡터 기반 클러스터링 및 분석

2절을 통하여 학습된 모델을 바탕으로 사고 영상에 대한 벡터를 산출한 뒤, K-Means 알고리즘을 사용하여 군집화한다. 이때, 클러스터 개수는 2부터 10까지 조정하여 클러스터링을 수행한 뒤, 클러스터 성능 지표인 Silhouette Score를 바탕으로 결정한다.

이후 형성된 대표적인 운전자 습관을 의미하는 각 클러스터에 대한 특징을 분석한다. 본 논문에서는 각 클러스터의 위험도를 분석하고자 한다. 이를 위해 클러스터에 속한 샘플들 중 자기 과실 비율이 100%인 샘플들의 비율인 Critical Ratio를 산출한다.

IV. Results

Table 1. Silhouette Score by number of Cluster

Number of cluster	Silhouette Score
2	0.41
3	0.43
4	0.46
5	0.46
6	**0.48**
7	0.46
8	**0.48**
9	**0.48**
10	**0.48**

클러스터 개수에 따른 Silhouette Score는 Table 1.과 같다. 이 중 Silhouette Score가 가장 높고, 클러스터 수가 가장 낮은 6을 기준으로 각 클러스터의 Critical Ratio를 Table 2.와 같이 산출하였다. 결과적으로 유사한 사고 전 영상들로 구성된 6개의 운전자 습관인 클러스터를 형성하였고, 1번 클러스터가 가장 Critical Ratio가 높았다. 이는 해당 클러스터가 가장 위험한 운전 습관을 지닌다고 해석할 수 있다.

Table 2. Critical Ratio for each cluster

Cluster	number of samples	Critical Ratio
1	1,894	**38.81%**
2	1,234	30.70%
3	1,076	27.13%
4	1,814	25.91%
5	1,508	22.02%
6	888	20.16%

V. Conclusions

본 논문은 운전 영상을 바탕으로 위험 운전 습관을 분석하기 위해 딥러닝 모델을 대조 학습하였고, 영상을 벡터로 변환한 뒤 클러스터링을 통해 유사한 운전자 습관을 지닌 클러스터를 형성하였다. 이후 각 클러스터의 위험도를 분석하였다. 추후, 딥러닝 모델 및 클러스터 성능 개선과 클러스터의 다양한 특징을 분석하기 위한 향후 연구를 진행할 예정이다.

REFERENCES

[1] Driver Group Clustering Technique and Risk Estimation Method for Traffic Accident Prevention, Journal of The Korea Society of Computer and Information, under review.

[2] S. Chen, K. Cheng, J. Yang, X. Zang, Q. Luo, and J. Li, “Driving Behavior Risk Measurement and Cluster Analysis Driven by Vehicle Trajectory Data,” Applied Sciences (Switzerland), vol. 13, no. 9, 2023

[3] Qian, Rui, et al. "Spatiotemporal contrastive video representation learning." Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. 2021.

[4] AI-Hub. Accessed: Jun. 16, 2024.[Online]. Available: https://www.aihub.or.kr/aihubdata/data/view.do?currMenu=115&topMenu=100&dataSetSn=597

[5] K. Sohn, “Improved Deep Metric Learning with Multi-class N-pair Loss Objective,” in Advances in Neural Information Processing Systems. 2016,