VCM 비트스트림 메타데이터 기반 비디오 압축 도메인 초고속 이상 탐지 기법

*신효승, *박세희, *변지윤, **곽상운, **정순흥, *서광덕
*연세대학교 소프트웨어학부, **한국전자통신연구원
*hyoseung8017@yonsei.ac.kr, *serra0508@yonsei.ac.kr, *pinkwin1004@yonsei.ac.kr,
**s.kwak@etri.re.kr, **zeroone@etri.re.kr, *kdseo@yonsei.ac.kr

Ultra-Fast Compressed-Domain Video Anomaly Detection Using VCM Bitstream Metadata

*Hyo-seung Shin, *Se-hee Park, *Ji-yun Byun, **Sang-woon Kwak,
**Soon-heung Jung, *Kwang-deok Seo
*Division of Software, Yonsei University, **ETRI

요 약

본 논문에서는 ISO/IEC 23888-2 VCM 비트스트림을 CABAC 디코딩 없이 표준 구문 정보만으로 분석하는 이상 탐지 기법을 제안한다. 제안 기법은 RSD에서 추출한 RoI 개수 a_C, GOP 내 위치에 맞추어 정규화한 프레임별 byte 크기 a_{TR}, 그리고 RoI 궤적의 위치 조건부 GMM을 활용하여 산출한 궤적 이탈도 a_{OBJ}를 필수 파라미터로 사용하며, 이들을 정상 학습 데이터의 분포에 따라 [0, 1] 구간으로 보정한 뒤 가중합하여 프레임별 이상 점수를 산출한다. Nested LOSO와 macro-AUROC로 검증한 결과, CUHK Avenue와 Street Scene 데이터셋에서 각각 0.7279와 0.5170을 기록하였으며, micro 집계로는 각각 0.7287과 0.5130을 나타냈다. 반면 소요 시간 측면에서 제안 기법은 동일 서버 조건에서 복호화를 포함한 속성 기반 방법보다 약 1.6×10^3배 빠르게 동작하여, 정확도 저하를 감수하는 대신 소요 시간을 크게 절감할 수 있음을 확인하였다.

1. 서론

기계가 영상을 분석하는 응용이 스마트 시티와 자율주행 분야 등에서 늘어남에 따라, ISO/IEC MPEG(Moving Picture Experts Group)은 이에 대응하여 기계 비전(Machine Vision) 태스크에 최적화된 VCM(Video Coding for Machines) 표준(ISO/IEC 23888-2)을 제정하고 있다[1][2]. 사람이 보는 화질을 기준으로 삼던 기존 코덱과 달리, VCM은 객체 검출이나 추적 등 다운스트림 태스크의 정확도를 기준으로 영상을 부호화한다. 이때 관심 영역(RoI, Region of Interest)의 위치와 크기가 메타데이터로 비트스트림에 함께 실릴 수 있어, 수신 측은 픽셀 복호화 없이 객체의 위치 정보를 읽어낼 수 있다[1].

비디오 이상 탐지(VAD, Video Anomaly Detection)는 영상에서 평소와 다른 행동이나 사건을 찾아내는 기술이다. 감시 카메라 영상은 압축된 비트스트림 형태로 저장되고 전송되지만, 기존 연구의 대부분은 이를 복호화한 뒤 optical flow나 skeleton pose를 추출하여 심층 신경망에 적용한다[3]. 다만 해당 과정은 탐지에 앞서 영상 전체를 복호화해야 하고, 객체 검출기와 특징 추출기도 별도로 구동해야 하므로 연산 부담이 존재한다.

특히 수백 대의 카메라가 운영되는 감시 환경에서는 복호화와 추론 비용이 병목으로 작용하며, 픽셀을 복원하는 과정은 개인정보 측면에서도 부담이 된다. VCM 표준[1]은 인코더가 검출한 RoI 정보를 복원 및 합성 데이터(RSD, Restoration and Synthesis Data)에 담아 비트스트림에 포함할 수 있도록 규정한다. 표준을 준수하는 비트스트림에는 객체 및 RoI에 관한 정보가 이미 내재될 수 있다는 뜻이다.

이에 본 논문에서는 VCM 비트스트림에 포함된 RoI 메타데이터를 활용하여 픽셀 복원 없이 동작하는 초고속 VAD 기법을 제안한다. 제안 기법은 기존의 객체별 속성 기반 방법[4]에 착안하여, VCM 비트스트림 도메인에서 CABAC(Context-Adaptive Binary Arithmetic Coding) 디코딩 없이 얻을 수 있는 RoI 개수, 프레임별 byte 크기, RoI 궤적 이탈도의 세 파라미터를 결합하여 VAD를 수행한다.

2. 관련 연구

기존 VAD 연구는 입력 형태에 따라 픽셀 도메인 기반

연구와 압축 도메인 기반 연구로 구분된다. 픽셀 도메인에서는 재구성 오차나 예측 오차를 이상 점수로 사용하는 방법이 대표적이다. 재구성 기반 방법[5]은 Memory-augmented Autoencoder로 정상 패턴을 학습하고, 입력 영상과 재구성 영상의 오차로 이상을 판별하며, 예측 기반 방법[6]은 미래 프레임을 예측한 뒤 실제 프레임과의 차이를 측정한다. 최근에는 객체별 속도 히스토그램과 skeleton pose 특징을 속성으로 추출하고 GMM(Gaussian Mixture Model)과 kNN(k-Nearest Neighbors)으로 밀도를 추정하는 방법[4]이 제안되었으며, 이 방법은 별도의 신경망 학습 없이 CUHK Avenue[7](이하 Avenue)에서 ROC 곡선 아래 면적(AUROC, Area Under the ROC Curve) 0.937(micro)을 기록하였다. 그러나 세 방법 모두 복호화된 픽셀 프레임을 입력으로 요구한다.

압축 도메인 기반 연구에서는 과거 MPEG-1/2의 움직임 벡터(MV, Motion Vector) 히스토그램을 활용한 접근법[8]이 제안되었으나, 움직임의 단순 통계적 특성에 의존하여 객체 단위 분석까지는 불가능하다는 한계가 있었다. 보다 최근에 제안된 확산 모델 기반의 방법[9]은 HEVC 비트스트림으로부터 I-frame과 MV를 추출 후 결합하지만, 실제 처리 과정에서는 I-frame을 부분적으로 복호화하여 적용하므로 픽셀에 의존하는 단계가 여전히 일부 포함되어 있다.

이처럼 기존 연구들은 픽셀 도메인 의존과 부분 복호화를 통한 픽셀 복원, 그리고 객체 단위의 분석 부재 중 적어도 하나의 한계를 지닌다. 또한 기존의 압축 도메인 기반 방법들은 사람의 시청을 목적으로 부호화된 비트스트림을 전제로 하였다. 반면 VCM이 제정되고 있는 시점에서 기계 분석을 위해 부호화된 비트스트림으로부터 CABAC 디코딩 과정 없이 객체 단위 이상을 탐지하는 분석 체계는 아직 확립되지 않았다.

3. 제안 기법

제안 기법은 두 단계로 구성된다. 첫 번째 단계에서는 VCM 비트스트림에서 성격이 다른 세 가지 파라미터인 RoI 개수, 프레임별 byte 크기, RoI 궤적의 위치 조건부 이탈도를 각각 파싱 및 산출한다. 그리고 두 번째 단계에서는 각 파라미터에 대해 정상 학습 분포를 기준으로 [0, 1] 구간으로 보정한 값을 가중합하여 프레임별 이상 점수 $S(t)$를 계산한다. 전체 작동 흐름은 [그림 1]과 같으며, 필수 파라미터 추출 방법은 3.1절에서, 파라미터값 보정과 이상 점수 산출은 3.2절에서 설명한다.

3.1 필수 파라미터 추출 방법

첫 번째 파라미터인 a_C는 한 프레임 내에 있는 RoI 개수를 의미하며, 군집 형성과 객체 수의 급변을 포착하는 밀도 파라미터이다. a_C는 식(1)과 같이 정의하며, 값이 0인 프레임은 무객체 프레임으로 정의한다. RSD unit은 VCM NAL의 길이 필드와 header로 식별하고, RoI 목록은 VCM 참조 소프트웨어(VCM-RS, VCM Reference Software)를 활용하여 payload 구문 필드에서 프레임별로 파싱한다.

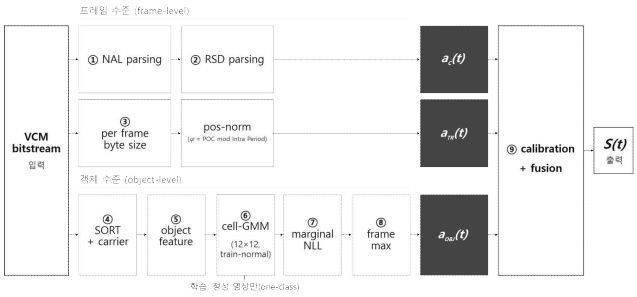
$$a_C = |RoI(t)| \quad — (1)$$

두 번째 파라미터인 a_{TR}은 프레임별 부호화된 byte 크기를 의미한다. 프레임 간 예측이 적용된 프레임에서는 예측에 실패한 잔차만 부호화되며, Rate-Distortion 최적화에 따라 잔차 에너지가 클수록 byte 크기가 증가한다. 따라서 프레임별 byte 크기는 장면 변화량을 대표하는 지표로 활용할 수 있다. 다만 화면 내 랜덤 액세스 지점(IRAP, Intra Random Access Point) 프레임은 장면 변화량과 무관하게 크기가 크고, temporal layer마다의 QP 차등에 따라 GOP 위치별 크기 패턴이 형성되는 점을 고려하여 위치 ϕ별로 정상 학습 중앙값과 중앙절대편차(MAD, Median Absolute Deviation)를 활용하여 정규화한 다음 사용한다.

$$a_{TR} = \frac{bytes(t) - med_{\phi}}{\max(MAD_{\phi}, 1)},\ \phi = POC(t) \bmod IntraPeriod \quad — (2)$$

세 번째 파라미터인 a_{OBJ}는 비트스트림의 RSD unit에서 파싱한 RoI 좌표로부터 SORT[10]로 생성한 궤적이 정상 범주에서 벗어난 정도를 나타낸다. 속도는 연속된 두 IRAP 프레임 간 변위로 산출되어 GOP 단위의 평균값만 얻어진다. 이에 평균 속력을 프레임별 byte 비중에 따라 분배하여 byte 크기가 큰 프레임에 더 큰 움직임을 부여한 carrier 속력 $v_{carrier}$를 함께 사용한다. 특징 벡터는 속도 v_x와 속력 v_{mag}, 방향 θ, 그리고 $v_{carrier}$를 포함하는 운동 성분과 정규화된 상자 폭 w_{norm} 및 면적 $area_{norm}$을 포함하는 형상 성분으로 구성된다. 같은 움직임이라도 위치에 따라 이상 여부가 달라지므로, 위치는 특징이 아닌 조건으로 사용한다. 이를 위해 화면을 12×12의 격자 cell로 나누어 cell마다 정상 학습 영상만으로 GMM을 적합한다[11]. 이후 시험 객체가 속한 cell 분포로부터 해당 객체가 떨어진 정도를 NLL(Negative Log-Likelihood)로 산출하며, 이 과정은 식(3)과 같다. 마지막으로 각 프레임에서 정상 분포로부터 가장 멀리 떨어진 객체의 NLL, 즉 객체별 NLL의 최댓값을 해당 프레임의 파라미터값 a_{OBJ}로 취한다. 다만 속도가 결측된 객체는 관측된 차원만으로 구성한 GMM 분포를 활용하여 NLL을 계산하며, 무객체 프레임은 보정 후의 해당 파라미터값을 0으로 설정한다.

$$NLL(x_O) = -\log \sum_k \pi_k \cdot N(x_O; \mu_{k,O}, \sum_{k,OO}) \quad — (3)$$



[그림 1] 제안 기법의 작동 흐름도

3.2 파라미터값 보정 및 이상 점수 산출

세 파라미터는 내부에서 산출되는 값의 단위가 상이하므로, 각 파라미터를 정상 학습 프레임의 경험적 누적분포 F에 통과시켜 정상 대비 이탈 정도를 나타내는 [0, 1] 구간의 값으로 보정한다. a_C와 a_{TR}은 정상보다 크거나 작은 양방향 이탈이 이상에 해당하므로 양방향 보정 $|2F-1|$을 적용하고, a_{OBJ}는 큰 값만이 이상에 해당하므로 단방향 보정 F를 적용한다.

$$\hat{a}_C = |2F_C(a_C)-1|,\ \hat{a}_{TR} = |2F_{TR}(a_{TR})-1| \quad (4)$$

$$\hat{a}_{OBJ} = F_{OBJ}(a_{OBJ})$$

식(4)를 통해 보정된 값을 식(5)로 결합하여 이상 점수를 산출한다. 가중치 λ는 세 파라미터별로 미리 정해둔 이산 후보값을 조합한 60개의 격자점에서 Nested LOSO(Leave-One-Scene-Out)[12]로 선택한다. 각 가중치를 가중치의 합으로 나누므로 각 파라미터의 기여는 가중치 비율 $\lambda_i/\sum\lambda$로 정해지며, 특정 파라미터의 효과가 제한적인 장면에서도 점수 범위가 안정적으로 유지된다.

$$S(t) = \frac{\lambda_C \cdot \hat{a}_C(t) + \lambda_{TR} \cdot \hat{a}_{TR}(t) + \lambda_{OBJ} \cdot \hat{a}_{OBJ}(t)}{\lambda_C + \lambda_{TR} + \lambda_{OBJ}} \quad (5)$$

4. 제안 기법 실험 및 성능 평가

본 장에서는 Avenue와 Street Scene[13]에서의 실험 결과를 보고한다. 4.1절에서는 평가 지표와 방법을 정의하고, 4.2절에서는 속성 기반 방법[4]과 제안 기법의 탐지 정확도를 기존 연구[3]의 관점에서 해석한다. 그리고 4.3절에서는 동일 서버에서 속성 기반 방법과 함께 소요 시간을 실측하여 비교한다.

4.1 평가 지표와 방법

실험에는 Avenue와 Street Scene을 사용하였고, 두 데이터셋을 VCM-RS v2.0으로 Intra Period 32와 64 조건에서 부호화하였다. Avenue는 고정된 지상 시점 카메라로 촬영한 640×360 해상도의 영상이다. 정상 학습 영상 16개와 시험 영상 21개로 구성되어 있으며, 시험 영상에는 달리기, 배회 등의 이상이 포함되어 있다. Street Scene은 도로를 위에서 내려다보는 고정 카메라로 촬영한 1280×720 해상도의 영상으로, 정상 학습 영상 46개와 시험 영상 35개로 이루어져 있다. 시험 영상에는 17종 205건의 이상이 포함되며, 무단횡단과 같이 위치에 따라 이상 여부가 달라지는 경우가 다수를 차지한다.

주 지표로는 프레임 단위로 산출한 시험 영상별 AUROC의 평균인 macro-AUROC를 채택하였다. 아울러 산출값의 해석을 위해 시험 프레임 전체를 하나의 집합으로 묶어 계산한 micro-AUROC도 함께 제시한다.

4.2 이상 탐지 정확도

Dataset	Attribute-based [4]		Intra Period	Proposed	
	macro	micro		macro	micro
Avenue	0.963	0.937	32	0.7279	0.7287
			64	0.7282	0.7443
Street Scene	N/A		32	0.5170	0.5130
			64	0.4417	0.4219

[표 1] 제안 기법의 정확도 실험 결과

Street Scene에서 제안 기법의 macro-AUROC는 Intra Period 32 기준 0.5170으로, 우연 수준인 0.5에 가깝다. 다만 기존 연구[3]에서 살펴볼 수 있듯이 전체 픽셀을 복호화하는 사전 기반 방법과 optical flow 및 foreground mask 기반 방법도 해당 데이터셋에서 0.48~0.61 수준의 micro-AUROC를 보인 것으로 보고되었다. Street Scene에는 무단횡단이나 자전거 도로 이탈과 같은 위치 의존적 이상이 다수 존재하며, 그림자와 수목, 차량 폐색에 따른 배경 변화도 탐지를 어렵게 하는 요인이다. 이를 고려하면 제안 기법의 0.5170(micro 0.5130)은 기존의 픽셀 도메인 기반 방법들이 보고한 성능 범위에 있으며, 해당 데이터셋에서는 제한된 입력 정보만으로도 픽셀 도메인 기반 방법과 유사한 수준의 결과를 얻을 수 있음을 보여준다.

Avenue에서는 동일 실험에서 0.7279(micro 0.7287)를 기록하였으며, 이는 속성 기반 방법의 정확도에는 미치지 못하지만, 기존 연구[3]에 보고된 픽셀 도메인 기반 방법의 성능 범위(micro)인 0.70~0.90의 하한 부근에 해당한다. 해당 데이터셋에는 달리기와 같은 운동성 이상뿐만 아니라 잔디 위의 가방과 같은 정적 이상도 다수 포함되어 있다[3][7]. 제안 기법은 RoI 정보와 프레임별 byte 크기만을 사용하므로, 외형 정보가 필요한 정적 이상 탐지에는 구조적 한계가 있음을 확인할 수 있다. 정성 분석에서도 시험 영상별로 이상 구간에서 이상 점수가 가장 높은 프레임과 점수가 가장 낮은 프레임을 살펴본 결과, Avenue에서 점수가 가장 높은 이상 프레임(TP, True Positive)은 객체의 궤적이 정상 분포를 벗어난 경우에, 점수가 가장 낮은 이상 프레임(FN, False Negative)은 객체가 관측되나 운동 성분이 정상 분포 안에 있는 경우에 주로 나타났다.

4.3 이상 탐지 소요 시간

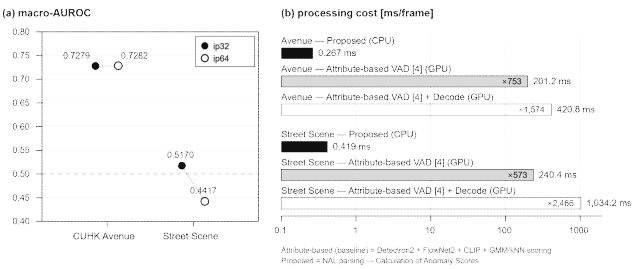
Method	소요 시간 (ms/frame)		실행 환경
	Avenue	Street Scene	
Attribute-based (미압축 픽셀 도메인)	201.2	240.4	GPU
Attribute-based (복호화 기반 픽셀 도메인)	420.8	1,034	GPU
Proposed	0.267	0.419	CPU

[표 2] 동일 서버 및 동일 프레임에 대한 탐지 소요 시간 비교

속성 기반 방법[4]의 소요 시간은 Detectron2 검출과 FlowNet2 optical flow, CLIP 특징 추출 및 GMM/kNN 채점으로 구성된 과정을 기준으로 하였으며, NVIDIA RTX A5500 GPU에서 측정하였다. 단, skeleton pose 추정 단계인 AlphaPose는

측정에서 제외하였으므로, [표 2]의 값은 속성 기반 방법 소요 시간의 최소치에 해당한다. 속성 기반 방법은 두 조건으로 나누어 측정하였다. 미압축 픽셀 도메인 조건은 원본 프레임 파일을 읽는 데서 시작되며, 복호화 기반 픽셀 도메인 조건은 VCM 비트스트림을 참조 디코더로 복호화하는 시간을 추가한 것이다. 제안 기법은 픽셀 복호화를 거치지 않으므로 NAL 파싱에서 이상 점수 산출까지의 시간만 측정하였다. 두 방법은 정확도가 서로 다르므로, 해당 비교의 목적은 같은 정확도에서의 속도 비교가 아니라 정확도와 소요 시간 사이의 절충 관계를 살펴보는 데 있다.

미압축 픽셀 도메인 조건에서 속성 기반 방법은 GPU로 프레임당 201~240 ms가 소요된다. 반면 제안 기법은 CPU 단일 워커로 프레임당 0.27~0.42 ms가 소요되어, 약 570~750배 빠른 속도를 확인할 수 있다. 실제 배포 환경에서는 두 방법 모두 같은 비트스트림에서 출발하므로, 속성 기반 방법에는 복호화 시간이 프레임당 219~793 ms 추가되어, 이 경우 소요 시간 격차는 약 1.6×10^3 ~ 2.5×10^3배까지 확대된다.



[그림 2] 제안 기법의 정확도-소요 시간 비교

5. 결론

본 논문에서는 VCM 비트스트림을 CABAC 디코딩 없이 파싱하여 얻은 세 가지 파라미터만으로 이상을 탐지하였으며, macro-AUROC는 Avenue와 Street Scene에서 각각 0.7279와 0.5170을 기록하였다. 이는 속성 기반 방법에 미치지 못하지만, 기존의 픽셀 도메인 기반 방법들이 보고한 성능 범위 안에 드는 값이다. 이와 함께 소요 시간은 속성 기반 방법의 약 0.04~0.17% 수준으로 감소하였으며, 정확도 저하를 일부 감수하는 대신 소요 시간을 크게 절감할 수 있음을 확인하였다. 향후에는 라벨 없이 가중치를 결정하는 방안과 정적 객체 이상을 위한 추가 파라미터를 검토하여 정확도를 개선하고자 한다.

ACKNOWLEDGEMENT

This research was supported by an Institute of Information and Communications Technology Planning & Evaluation grant funded by the Korean government (MSIT) (No. 2020-0-00011, Video Coding for Machine) and by the Regional Innovation System & Education(RISE) program through the Gangwon RISE Center, funded by the Ministry of Education(MOE) and the Gangwon State(G.S.), Republic of Korea.(2026-RISE-10-006)

참 고 문 헌

[1] ISO/IEC JTC1/SC29/WG04 N0793, "Text of ISO/IEC DIS 23888-2 Video Coding for Machines," Draft International Standard, 2026.

[2] L. Duan et al., "Video coding for machines: A paradigm of collaborative compression and intelligent analytics," IEEE Trans. Image Process., vol. 29, pp. 8680-8695, 2020.

[3] B. Ramachandra, M. J. Jones, and R. R. Vatsavai, "A survey of single-scene video anomaly detection," IEEE Trans. Pattern Anal. Mach. Intell., vol. 44, no. 5, pp. 2293-2312, 2022.

[4] T. Reiss and Y. Hoshen, "An attribute-based method for video anomaly detection," Trans. Mach. Learn. Res. (TMLR), 2025.

[5] D. Gong et al., "Memorizing normality to detect anomaly: Memory-augmented deep autoencoder for unsupervised anomaly detection," in Proc. IEEE ICCV, 2019, pp. 1705-1714.

[6] W. Liu, W. Luo, D. Lian, and S. Gao, "Future frame prediction for anomaly detection - A new baseline," in Proc. IEEE CVPR, 2018, pp. 6536-6545.

[7] C. Lu, J. Shi, and J. Jia, "Abnormal event detection at 150 FPS in MATLAB," in Proc. IEEE ICCV, 2013, pp. 2720-2727.

[8] N. Kiryati, T. Riklin Raviv, Y. Ivanchenko, and S. Rochel, "Real-time abnormal motion detection in surveillance video," in Proc. ICPR, 2008, pp. 1-4.

[9] H. Liu, L. He, M. Zhang, and F. Li, "VADiffusion: Compressed domain information guided conditional diffusion for video anomaly detection," IEEE Trans. Circuits Syst. Video Technol., vol. 34, no. 9, pp. 8398-8411, 2024.

[10] A. Bewley, Z. Ge, L. Ott, F. Ramos, and B. Upcroft, "Simple online and realtime tracking," in Proc. IEEE ICIP, 2016, pp. 3464-3468.

[11] V. Mahadevan, W. Li, V. Bhalodia, and N. Vasconcelos, "Anomaly detection in crowded scenes," in Proc. IEEE CVPR, 2010, pp. 1975-1981.

[12] G. C. Cawley and N. L. C. Talbot, "On over-fitting in model selection and subsequent selection bias in performance evaluation," J. Mach. Learn. Res., vol. 11, pp. 2079-2107, 2010.

[13] B. Ramachandra and M. J. Jones, "Street Scene: A new dataset and evaluation protocol for video anomaly detection," in Proc. IEEE/CVF WACV, 2020, pp. 2569-2578.