Ultra-Fast Compressed-Domain Video Anomaly Detection Using VCM Bitstream Metadata

신효승[1], 박세희[1], 변지윤[1], 곽상운[2], 정순흥[2], 서광덕[1]*

[1]연세대학교 소프트웨어학부 [2]한국전자통신연구원(ETRI) *kdseo@yonsei.ac.kr

연구 배경

ISO/IEC MPEG은 기계 비전 태스크의 정확도를 기준으로 영상을 부호화하는 VCM(Video Coding for Machines) 표준(ISO/IEC 23888-2)을 제정하고 있으며, VCM 비트스트림에는 RoI(Region of Interest)의 위치와 크기가 복원 및 합성 데이터(RSD)로 담길 수 있다. 하지만 비디오 이상 탐지(VAD) 연구 대부분은 영상을 복호화한 뒤 optical flow나 skeleton pose를 추출하여 신경망에 입력하므로, 수백 대의 카메라를 관제하는 환경에서는 복호화와 추론이 병목이 된다. 압축 도메인 방법도 사람의 시청용 비트스트림을 전제로 하며, 객체 단위 분석이 불가능하거나 I-frame을 부분 복호화한다. 따라서 기계 분석용 비트스트림에서 픽셀 복호화 없이 객체 단위 이상을 탐지하는 경량 방법이 필요하다.

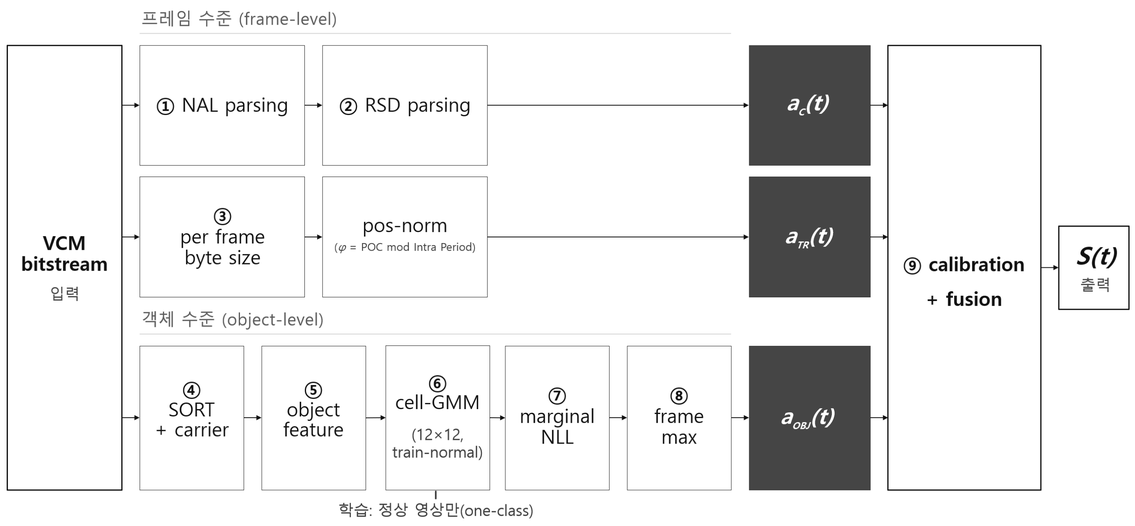
연구 목적

본 논문에서는 VCM 비트스트림의 RoI 메타데이터를 활용하여 픽셀 복원 없이 동작하는 초고속 VAD 기법을 제안한다. 속성 기반 방법으로부터 착안하여, 엔트로피 복호화 없이 획득할 수 있는 세 가지 파라미터를 결합하여 VAD를 수행하며, 제안 기법의 설계 제약 조건은 다음과 같다.

- CABAC 복호화 없음: VCM 계층 구문만을 파싱한다.
- 픽셀 미사용: 복원 영상과 픽셀 기반 신경망을 쓰지 않는다.
- 표준 비트스트림: VCM-RS로 부호화한 표준 비트스트림을 그대로 입력한다.

제안 기법

제안 기법은 VCM 비트스트림에서 세 파라미터를 파싱하고 산출한다. 산출된 각 파라미터를 정상 학습 분포 기준으로 [0, 1] 구간에 보정한 뒤, 그 값을 가중합하여 프레임별 이상 점수 S(t)를 계산한다. 학습에는 정상 영상만 사용한다.



[그림 1] 제안 기법의 작동 흐름도

- a_C (RoI 개수): 군집 형성과 객체 수의 급변을 포착한다. RSD unit의 RoI 목록을 프레임별로 파싱하며, 값이 0이면 무객체 프레임이다.

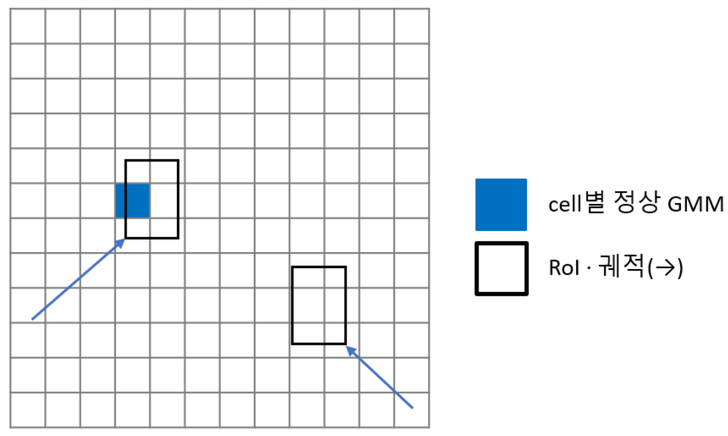
$$a_C(t) = |RoI(t)| \quad — \ (1)$$

- a_{TR} (프레임별 byte 크기): 화면 간 예측 프레임은 잔차만 부호화하므로 byte 크기가 장면 변화량을 대표한다. IRAP과 temporal layer별 QP 차등으로 인해 GOP 위치마다 크기 패턴이 생기는 점을 활용하여, 위치별 정상 중앙값과 MAD로 정규화한다.

$$a_{TR}(t) = \frac{bytes(t) - med_{\varphi}}{\max(MAD_{\varphi}, 1)}, \ \varphi = POC(t) \ mod \ IntraPeriod \quad — \ (2)$$

- a_{OBJ} (궤적 이탈도): RoI 좌표를 SORT로 연결해 궤적을 만든다. 이 궤적에서 운동 성분(속도, 속력, 방향, carrier 속력)과 형상 성분(폭, 면적)을 구한다. carrier 속력은 IRAP 간 평균 속력을 프레임별 byte 비중으로 분배한 값이다. 같은 움직임도 프레임 내 위치에 따라 이상 여부가 상이하므로, 화면을 12×12 cell로 나누어 cell별로 GMM을 적합한다. 프레임 값은 객체별 NLL의 최댓값으로 정한다.

$$NLL(x_O) = -log \sum_k \pi_k \cdot N(x_O; \ \mu_{k,O}, \sum_{k,OO} \ ) \quad — \ (3)$$



[그림 2] 위치 조건부 GMM 개념도

- 보정과 결합: a_C와 a_{TR}은 크거나 작은 값이 모두 이상이므로 |2F−1|로 보정한다. a_{OBJ}는 큰 값만 이상이므로 F로 보정한다. 가중치 λ는 60개 후보 중에서 Nested LOSO(Leave-One-Scene-Out)[12]로 고르며, 평가 영상의 라벨은 선택에 쓰이지 않는다.

$$\hat{a}_C = |2F_C(a_C) - 1|, \ \ \hat{a}_{TR} = |2F_{TR}(a_{TR}) - 1|, \ \hat{a}_{OBJ} = F_{OBJ}(a_{OBJ}) \quad — \ (4)$$

$$S(t) = \frac{\lambda_C \cdot \hat{a}_C(t) + \lambda_{TR} \cdot \hat{a}_{TR}(t) + \lambda_{OBJ} \cdot \hat{a}_{OBJ}(t)}{\lambda_C + \lambda_{TR} + \lambda_{OBJ}} \quad — \ (5)$$

실험 결과

CUHK Avenue와 Street Scene 데이터셋을 VCM-RS v2.0으로 부호화하였고, Intra Period는 32와 64로 두었다. 주 지표는 시험 영상별 AUROC의 평균인 macro-AUROC이다. 모든 프레임이 이상인 영상은 평가에서 제외하였으며, 전통적인 픽셀 기반 VAD 연구의 정확도와 비교하고자 시험 프레임 전체로 계산한 micro-AUROC도 함께 제시한다.

[표 1] 제안 기법의 정확도 실험 결과

Dataset	Pixel-based		Intra Period	Proposed	
	micro	macro		micro	macro
CUHK Avenue	0.70 ~ 0.90	N/A	32	0.7279	0.7287
			64	0.7282	0.7443
Street Scene	0.48 ~ 0.61	N/A	32	0.5170	0.5130
			64	0.4417	0.4219

제안 기법의 Intra Period에 따른 탐지 정확도는 [표 2]와 같으며, micro-AUROC에서는 전통적인 픽셀 기반의 VAD 연구에서 보고된 정확도 범위 안에 든다. 다만 신경망과 다수의 픽셀 기반 검출기를 사용하는 속성 기반 방법의 보고값(Avenue micro 0.937, macro 0.963)에는 미치지 못한다. 동적 이상은 제안 기법을 통해 일부 탐지할 수 있지만, 정적 이상에 대해서는 외형 정보가 있어야 찾을 수 있어서, 세 파라미터만으로는 탐지하기 어렵다는 한계를 지닌다.

[표 2] 동일 서버 및 동일 프레임에 대한 탐지 소요 시간 비교

Dataset	CUHK Avenue	Street Scene	Environment
Attribute-based (미압축 픽셀 도메인)	201.2 ms/frame	240.4 ms/frame	NVIDIA RTX A5500
Attribute-based (복호화 기반 픽셀 도메인)	420.8 ms/frame	1,034 ms/frame	
제안 기법	0.267 ms/frame	0.419 ms/frame	CPU 1 worker

제안 기법은 CPU 1 worker로 프레임당 0.267~0.419 ms가 걸렸다. GPU에서 미압축 프레임을 처리하는 속성 기반 방법보다 약 570~750배 빠르며, 같은 비트스트림에서 출발해 복호화 시간까지 더하면 격차는 약 1,580~2,470배임을 확인할 수 있다. 두 방법은 정확도가 다르므로, 이 비교는 정확도와 처리 시간 사이의 관계를 보여 준다.

결론

본 논문에서는 VCM 비트스트림을 엔트로피 복호화 없이 파싱하여 얻은 세 파라미터만으로 비디오 이상을 탐지하는 기법을 제안하였다. Intra Period 32에서 macro-AUROC는 Avenue 0.7279, Street Scene 0.5170이었다. 속성 기반 방법에는 미치지 못하였으나 픽셀 기반 방법의 보고 범위 안에 들었으며, 처리 시간은 속성 기반 방법의 0.04~0.17% 수준으로 감소하였다. 향후에는 정적 이상 탐지를 위한 추가 파라미터를 검토할 예정이다.