한국 융합신호처리학회

한국 융합신호처리학회 논문지 제 00권 00편 제 00 호 pp. 000-000, 2020

TAREF: 운전자 특성 및 실시간 행동 분석 기반 교통사고 위험도 산출 프레임워크

김태욱[1], 주준경[1], 신효승[1], 박규민[2], 홍정희[1*]

[1]연세대학교 소프트웨어학부, [2]연세대학교 컴퓨터정보통신공학부

TAREF: Traffic Accident Risk Evaluation Framework based on Driver Characteristics and Real-Time Behavioral Analysis

Tae-Wook Kim[1], Jun-Kyung Ju[1], Hyo-Seung Shin[1], Gue-Min Park[2], Ellen J. Hong[1*]

[1]Division of Software, Yonsei University

[2]Department of Computer & Telecommunications Engineering, Yonsei University

요 약 현대 사회에서 교통사고는 인간의 생명과 안전을 위협할 뿐만 아니라 국가에 경제적 손실을 일으킨다. 교통사고를 예방하여 시민들의 안전을 확보함과 동시에 국가의 경제적 손실을 감소시키는 것은 해결해야 할 매우 중대한 문제이다. 최근 딥러닝 기술의 발전에 따라 도로의 시공간적 특성을 기반으로 교통사고 위험도를 예측하는 연구가 활발히 진행되고 있다. 그러나, 교통사고에 중요한 요소인 인적요소를 활용하여 교통사고 위험도를 산출하는 연구는 활발히 수행되지 않았다. 본 논문은 기존의 도로 시공간적 특성 기반 교통사고 확률 예측 연구에 운전자의 특성에 따른 위험도와 실시간 운전자 이상행동 및 시선 분산에 따른 위험도를 결합하여 종합적으로 운전자에 개인화된 위험도인 Comprehensive Traffic Risk Level(CTRL)을 산출하기 위한 Traffic Accident Risk Evaluation Framework(TAREF)를 제시한다. 이러한 교통사고 위험도 산출 방법을 통해 향후 교통사고 예방을 위한 연구 및 정책 수립에 있어서 중요한 기반을 제공할 것으로 기대된다.

• 주제어 : 교통사고 예측, 운전자 특성 분석, Clustering, 운전자 행동 분석, 시선 처리, 실시간 예측

Abstract In modern society, traffic accidents not only threaten human lives and safety but also result in economic losses for the nation. Preventing traffic accidents to ensure the safety of citizens while reducing the economic losses of the country is a very significant issue that needs to be addressed. With the recent advancements in deep learning technology, research on predicting the risk of traffic accidents based on the spatiotemporal characteristics of roads is actively ongoing. However, research on calculating the risk of traffic accidents by utilizing human factors, which are crucial elements in accidents, has not been actively pursued. This paper presents a Traffic Accident Risk Evaluation Framework (TAREF) to calculate the Comprehensive Traffic Risk Level (CTRL), which is personalized risk for drivers by combining the risk according to driver characteristics with real-time driver aberrant behavior and gaze dispersion. It is expected that such a method for calculating traffic accident risk will provide an important foundation for future research and policy-making aimed at preventing traffic accidents.

• Key Words : Traffic Accident Prediciton, Driver Characteristics Analysis, Clustering, Driver Behavior Analysis, Gaze Processing, Real-Time Prediction

Received 29 November 2020, Revised 29 December 2014, Accepted 21 January 2020 (출판사에서작성)

*** Corresponding Author** Ellen J. Hong, Division of Software, Yonsei University, 1 Yonseidae-gil, Wonju, Gangwon-do, Korea.
E-mail: ellenhong@yonsei.ac.kr

Ⅰ. 서론

현대 사회에서 교통사고는 인간의 생명과 안전을 위협할 뿐만 아니라 국가에 경제적 손실을 일으킨다. 도로교통공단 보도자료[1]에 따르면, 2022년 도로교통사고로 인한 사회적 비용은 약 26조 2,833억이 발생하였다. 한국 국가지표체계[2]에 따르면 한국의 도로교통사고 사망률은 2000년대부터 꾸준히 감소하고 있으나 국제적으로 여전히 높은 수준이다. 이처럼 교통사고는 국가에 큰 손실을 일으키며 시민의 안전에 위험한 요소이다. 따라서 교통사고를 예방하여 시민들의 안전을 확보함과 동시에 국가의 경제적 손실을 감소시키는 것은 해결해야 할 매우 중대한 문제이다.

최근 딥러닝 기술의 발전에 따라 교통사고 위험도를 예측하는 연구가 활발히 진행되고 있다. 그중 도로와 인접도로 간의 Graph 적인 특성을 시간에 따라 Sequential 하게 추출한 뒤, 시공간적인 도로의 특징을 잘 반영하여 학습할 수 있는 딥러닝 모델을 사용하여 교통사고 위험도를 예측하는 연구가 주로 수행되었다[3]. 그러나, 교통사고는 도로의 교통량, 교통 속도와 같은 외부 요인에 영향을 받을 뿐만 아니라 안전 운전 불이행과 같은 운전자 관련 요인의 영향을 받아 발생하는 문제이다. 즉, 같은 도로 환경이라도 운전자에 따라 교통사고 확률은 달라질 수 있다. 따라서 교통사고를 정확하게 예측하기 위해서는 운전자의 특성과 실시간 상태를 반영해야 할 필요가 있다.

본 논문은 도로의 시공간적 요인뿐만 아니라 운전자의 인적 특성과 실시간 운전자의 행동을 바탕으로 종합적인 교통사고 위험도를 산출할 수 있는 Traffic Accident Risk Evaluation Framework (TAREF)를 제시하고자 한다. TAREF는 사고 운전자 데이터셋을 바탕으로 Clustering을 수행하여 운전자 특성에 따른 Risk Level을 산출하고 운전자의 실시간 이상행동 및 시선 처리에 따른 Score를 산출한 뒤, 이를 바탕으로 기존에 연구된 도로의 시공간적 특성에 따른 위험도와 결합하는 방법을 제시하고자 한다.

Ⅱ. 관련연구

2.1 운전자 특성 분석

교통사고 예방을 위해 운전자의 특성을 파악하고 위험한 운전자 특성을 도출하는 관련 연구들은 다음과 같다. 택시에 장착된 GPS 장치를 바탕으로 운전자 행동 데이터를 분석한 [4]는 Dynamic Time Warping(DTW)와 Hierarchical Clustering을 바탕으로 Clustering을 수행한 뒤 Hidden Markov Model(HHM)을 사용하여 Cluster 결과가 수렴하도록 하여 DTW 및 HMM의 클러스터링 방법이 운전자 행동을 효과적으로 분류할 수 있음을 보였고 운전자 그룹을 안전과 관련된 특성을 기반으로 분석하였다. 횡방향 안정성 지표, 종방향 안정성 지표 등 4가지의 위험 산출 지표를 바탕으로 차량 운행 기록으로 구성된 NGSIM 데이터셋으로부터 차량 속도, 가속도 등에 대한 위험도를 산출하여 K-Means Clustering을 적용한 [5]는 각 위험 산출 지표간의 Peason 상관계수가 낮은 것을 바탕으로 각 위험 산출 지표가 서로 다른 운전자의 위험 습관을 효과적으로 나타낼 수 있음을 보였고, criteria importance through intercriteria correlation (CRITIC) 방법을 사용하여 4가지 위험 산출 지표 간의 가중치를 구하였으며, 최종적으로 운전자 그룹을 Dangerous, Aggressive, Safe, Conservative 총 4가지의 risk type으로 분류 및 분석하였다. 위 연구들과 같이 차량의 가속계 센서를 바탕으로 구축된 운전자 그룹들은 실제 사고 데이터를 바탕으로 구축된 운전자 그룹이 아니므로 사고와 직간접적인 관계가 없어 교통사고 관련 Risk Level을 산출할 수 없음에 주목한 [6]은 TAAS 교통사고 데이터셋에 구성된 가해 운전자 인적 특성을 바탕으로 Clustering Algorithm 성능 비교를 통해 가장 적합한 Clustering Algorithm인 MeanShift를 사용하여 운전자 그룹을 형성하였고, 각 그룹에 대한 평가 지표인 사고 빈도수와 사고 심각도를 바탕으로 각 운전자 그룹별 Risk Level을 산출하였다. 이를 바탕으로 운전자 특성에 해당하는 Risk Level을 산출할 수 있었다.

가속계 센서를 바탕으로 위험 운전자, 안전 운전자 등의 운전자 그룹을 Categorical하게 분류하는 것이 아닌, 사고와 밀접한 관계가 있는 사고 데이터셋을 바탕으로 운전자 그룹을 형성하여 각 그룹의 위험도를 정량적으로 도출하는 것은 효과적이

다. 그러나 운전자 특성은 Clustering 결과로 형성된 운전자 그룹 중 하나로 일치하는 것이 아닌 여러 가지 그룹의 특성이 혼합된 형태로 존재할 수 있다. 따라서 본 논문은 [6]과 같은 동일한 방식으로 운전자 특성에 따른 Risk Level을 산출하되, Gauss Mixture Clustering Algorithm을 사용하여 특정 운전자가 각 그룹에 속할 확률을 바탕으로 더 정확한 운전자의 Risk Level을 산출하고자 한다.

2.2 실시간 운전자 행동 분석

운전자의 실시간 행동을 분석 및 위험도를 도출하여 교통사고를 예방하기 위한 관련 연구들은 다음과 같다. 운전자의 이상행동은 교통사고를 유발하기 때문에 이를 사전에 방지하기 위한 모델을 제시한 [7]은 CNN-LSTM 기반의 모델을 바탕으로 운전자의 이상행동을 실시간으로 식별하는 방법을 제시하였다. 운전자의 시선 분산은 교통사고의 약 80%에 관련이 있을 정도로 교통사고를 유발하는 주된 원인이므로 운전자 시선 정보 시각화하여 교통사고를 예방하고자 한 [8]은 기존의 Eye-Tracker를 활용한 시선추적방식은 적외선 카메라가 필요하기에 비용의 문제가 발생함을 지적하여, 일반 카메라 영상으로부터 운전자의 시선을 예측하기 위한 MTCNN(Multi-Task Convolutional Neural Network) 모델을 제시하였다. 운전자의 이상행동과 시선 분산을 동시에 반영하여 Risk Score를 산출하는 방법을 제시한 [9]는 MCGaze 모델을 사용하여 운전자 시선 Vector를 추출하고 Temporal Segment Network(TSN)를 사용하여 운전자의 이상행동을 탐지하였고, 운전자 시선 방향과 탐지된 이상행동의 종류에 따라 Risk Score를 실시간으로 계산하였다.

위 연구들과 같이 운전자의 시선 분산과 이상행동은 교통사고를 유발하는 큰 요소들이므로, 실시간으로 운전자의 시선 분산과 이상행동을 탐지하여 교통사고 위험도 산출 및 예방하는 것 매우 중요하다. 따라서, 본 논문에서는 [9]를 바탕으로 실시간 운전자의 이상행동 및 시선에 따른 Risk Score를 계산하여 운전자 사고 위험도에 반영하고자 한다.

III. 연구 방법

본 논문은 기존의 수행된 연구인 도로의 시공간적 특성 기반 교통사고 확률에 운전자의 특성과 실시간 이상행동 및 시선 분산에 따른 위험도를 결합하여, 종합적이고 운전자 개인화된 Risk Level을 산출하기 위한 Traffic Accident Risk Evaluation Framework(TAREF)를 제안하고자 한다. 이때, 도로에 시공간적 특성에 따른 교통사고 확률이 5분 단위로 제공된다고 가정한다. 3.1절에서는 운전자 특성에 따른 Risk Level을 산출하는 방법에 대해 설명하고, 3.2절에서는 실시간 Risk Score 산출에 대해 다루며, 마지막으로 3.3절에서는 3가지 요소를 모두 고려하여 Risk Level을 산출하는 Framework에 대해 다룬다.

3.1 운전자 특성 기반 위험도 산출

Table 1. A Sample of Traffic Accident Dataset

Feature	Values
Accident ID	2021060800100130
Accident Date	2021 June 8st, 10:00
Day of the Week	Tuesday
District	Seoul, Guro-gu Oryu-dong
Accident Description	Serious Accident
Number of Fatalities	0
Number of Serious Injuries	1
Number of Minor Injuries	0
Number of Injury Reports	0
Accident Type	Car vs. Pedestrian
Violation of Law	Failure to Drive Safely
Road Surface Condition	Dry
Weather Condition	Clear
Road Type	Single Lane
Attacking Driver's Vehicle Type	Passenger Car
Attacking Driver's Gender	Male
Attacking Driver's Age	73
Attacking Driver's Injury Severity	No Injury
Victim Driver's Vehicle Type	Pedestian
Victim Driver's Gender	Female
Victim Driver's Age	72
Victim Driver's Injury Severity	Serious Injury

TAAS에서 제공하는 서울특별시 대상 2021년 교통사고 데이터셋[10]을 사용하여 Clustering을 통해 운전자 그룹 및 각 그룹의 Risk Level을 산출한다. 해당 데이터셋은 Table 1.과 같은 샘플로 구성되어 있다. 본 논문은 [6]과 동일한 방식으로 해당 데이터셋에서 총 5개의 Feature인 Month, 도로형태, 가해

운전자 차종, 가해 운전자 성별, 사해 운전자 연령을 추출한 뒤, 통계자료 기반 전처리를 적용하여 Clustering을 적용하고, 형성된 운전자 그룹의 사고 빈도수와 사고 심각도를 바탕으로 Risk Level을 산출한다. 이때

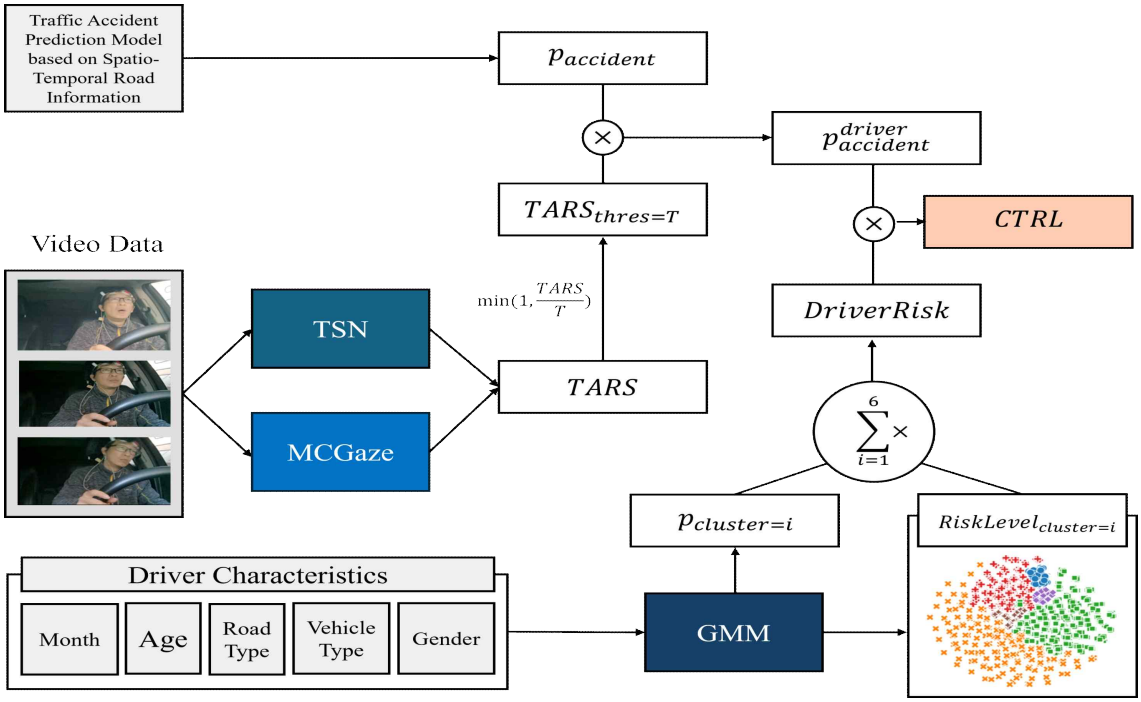

Fig 1. Overview of Traffic Accident Risk Evaluation Framework

Clustering의 경우 Gauss Mixture Model(GMM)을 사용한다. GMM은 Gaussian 다변수 정규 분포를 사용하여, 다른 Clustering Algorithm과는 다르게 각 Cluster 포함될 확률을 계산 가능한 Clustering Algorithm이다. 이를 사용하여 임의의 운전자 특성이 GMM을 통해 형성된 n개의 각 그룹의 속할 확률을 구할 수 있도록 한다. 학습된 GMM을 바탕으로 임의의 운전자에 대하여 각 n개의 그룹 중 그룹 i에 속할 확률을 $p_{cluster=i}$, 각 n개의 그룹의 Risk Level을 $RiskLevel_{cluster=i}$라고 할 때, 임의 운전자의 특성에 따른 최종 Risk Level인 $DriverRisk$를 식 (1)과 같이 산출한다.

$$DriverRisk = \sum_{i=1}^{n} p_{cluster=i} \times RiskLevel_{cluster=i} \quad (1)$$

GMM 학습 실험 설계는 [6]과 동일하게 진행하였으며, 성능 및 클러스터 수와 $RiskLevel_{cluster=i}$ 도출 결과 등 자세한 실험 결과 및 분석은 4장에서 다룬다.

3.2 실시간 운전자 행동 기반 Risk Score 산출

실시간으로 운전자의 이상행동과 시선을 탐지하여 Risk Score를 산출하기 위해서, 본 논문은 [9] 와 같이 차량 내부 운전자 영상에 대하여 이상행동 탐지 모델인 TSN(Temporal Segment Network)와 시선 벡터 추출을 위한 모델인 MCGaze를 사용하여 매 150 Frame 마다 이상행동에 따른 Risk Score와 시선 분산에 따른 Risk Score에 대한 곱들의 합인 TARS(Traffic Accident Risk Score)를 산출한다. 이때, TSN 모델의 경우 차량 내부 영상에서 운전자의 이상 행동을 분류하는 다중 분류 문제 대해서 F1-Score 0.9892의 높은 성능을 보였고, MCGaze 모델은 Gase360 Dataset에 대해서 모델이 예측한 시선 각도와 실제 각도간의 차이에 대한 MAE가 9.81로 매우 높은 성능을 보였다.

3.3 Traffic Accident Risk Evaluation Framework

도로에 대한 시공간적 특성에 따른 확률에 이상행동 및 시선 분산에 따른 Risk와 운전자 특성에 따른 Risk를 반영하여 개인화된 Traffic Accident Risk Evaluation Framework의 구조는 Fig 1.과 같으며 자세한 설명은 다음과 같다.

임의 도로에 대한 시공간적 특성에 따른 사고 확률을 $p_{accident}$라고 할 때, 동일한 시간과 도로 위에서 시선 분산과 이상행동이 적은 운전자는 실질적으로 $p_{accident}$ 보다 낮은 사고 확률을 가지고, 이와 반대로 이상행동과 시선 분산이 많은 운전자는 $p_{accident}$와 비슷한 사고 확률을 가진다고 볼 수 있다. 이를 바탕으로 도로 시공간적 특성에 따른 사고 확률 $p_{accident}$에 실시간 운전자 행동에 따른 Risk Score인 TARS가 식(2)과 같이 [0, 1] 사이의 값을 가지며 Threshold T를 초과하면 1의 값을 가지도록 변형되어 적용된, 운전자의 실시간 행동에 따라 개인화된 사고 확률 $p_{accident}^{driver}$는 식 (3)와 같이 산출한다. 이를 통해 운전자의 실시간 TARS 값이 낮을수록 사고가 발생할 확률이 낮아지는 것을 반영할 수 있다.

$$TARS_{thres=T} = \min(1, \frac{TARS}{T}) \quad (2)$$

$$p_{accident}^{driver} = TARS_{thres=T} \times p_{accident} \quad (3)$$

3.1절에서는 사고 운전자 정보를 바탕으로 GMM을 통해 Clustering을 진행한 뒤, 구축된 각 운전자 그룹의 Risk Level을 도출하였다. 즉, GMM은 임의 운전자 정보를 사고 운전자라는 가정하에 운전자 특성에 따라 그룹 i에 속할 확률 $p_{cluster=i}$를 산출한다. 이는 식 (4)와 같이 사고가 발생하였을 때 그룹 i에 속할 조건부 확률을 의미한다. 그러므로, 산출 과정에서 $p_{cluster=i}$가 포함된 $DriverRisk$는 사고가 발생하였을 때 조건부 확률에 따른 운전자 특성에 대한 Risk Level이다.

$$p_{cluster=i} = P(cluster = i \mid accident) \quad (4)$$

따라서, 사고가 발생할 확률을 $p_{accident}^{driver}$로 사용하여 식 (5)와 같이 $DriverRisk$에 적용함으로써, 도로의 시공간적 특성에 따른 사고 확률과 이상행동 및 시선 분산에 따른 Risk와 운전자 특성에 따른 Risk를 종합적으로 적용한 최종적인 운전자 개인화된 Comprehensive Traffic Risk Level(CTRL)을 산출할 수 있다.

$$CTRL = DriverRisk \times p^{driver_{accident}} \quad (5)$$

Ⅳ. Clustering 결과 및 분석

Table 2. Risk Level Calculation Results by Cluster

Cluster	Frequency	Severity	Frequency Rank	Severity Rank	Risk Level
0	1678	26027.17	1	5	2
1	40224	19659.72	6	3	5
2	24023	27785.21	5	6	6
3	14382	18319.23	4	2	2
4	1777	25161.4	2	4	2
5	2829	17317.31	3	1	1

GMM 학습 결과 및 산출된 $RiskLevel_{cluster=i}$는 Table 2.과 같고 T-SNE를 통해 시각화된 운전자 그룹 분포는 Fig 2.와 같다. 총 6개의 운전자 집단이 형성되었으며 각 운전자 집단의 사고 빈도수(Frequency)와 사고 심각도(Severity)를 산출하였다. 이후 각 지표별 순위를 1부터 6까지 부여한 뒤 종합적인 순위인 $RiskLevel_{cluster=i}$을 산출하였다. 이를 바탕으로 $CTRL$ 을 산출할 경우 1부터 6사이의 값을 가진다. 결론적으로 임의 운전자의 $CTRL$이 6에 가까울수록, 자신이 위치한 도로의 상황뿐만 아니라 자신의 특성 및 실시간 상태를 고려하였을 때 매우 위험한 상황임을 의미한다.

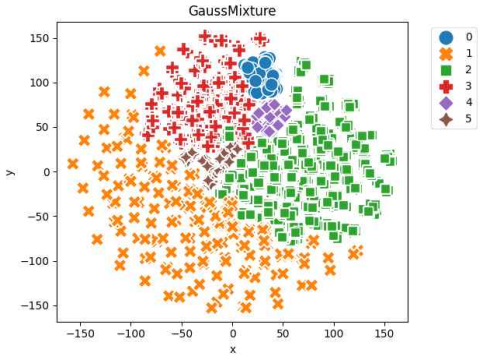

Fig 2. GaussMixture T-SNE Result

Ⅵ. 결론

본 논문은 기존의 도로의 시공간적 특성 기반의 교통사고 위험도 예측 연구를 운전자 특성에 따른 위험도와 실시간 운전자 이상행동 및 시선 분산에 따른 위험도를 결합하여 종합적으로 개인화된 교통사고 위험도 산출하기 위한 Traffic Accident Risk Evaluation Framework (TRAEF)를 제안하였다. 이 과정에서 운전자의 특성이 Clustering을 통해 형성된 그룹 중 하나로 반드시 해당되는 것이 아닌 점을 반영하기 위해 Gauss Mixture Model(GMM)을 사용하여 기존의 연구보다 정확한 운전자 특성에 따른 위험도인 $DriverRisk$를 산출하였다. 또한 기존의 도로 시공간적 특성 기반 사고확률에 운전자의 실시간 이상행동 및 시선 분산에 따른 사고 확률의 변화를 반영하기 위한 $p_{accident}^{driver}$ 을 제시하였다. 최종적으로 TRAEF를 통해 Comprehensive Traffic Risk Level(CTRL) 산출하여 운전자의 종합적이고 개인화된 위험도를 산출하는 방법을 제시하였다. 그러나, 운전자 내부 영상, 교통사고 데이터가 결합된 데이터셋이 존재하지 않기 때문에, 통합적인 검증 과정이 필요한 $p_{accident}^{driver}$를 산출하는 과정에서 필요한 Threshold T에 대하여 적절한 값을 제시하지 못하였다는 한계점이 존재하였다. 그러므로, 이와 같은 한계점을 보완하고 시선 분산, 이상행동, 운전자 특성뿐만 아니라 운전자 사고 블랙박스 영상과 같은 다양한 데이터들을 활용하여 더욱 정확한 교통사고 위험도 산출 방법을 추가 연구로 진행할 예정이다.

ACKNOWLEDGMENTS

이 성과는 정부(과학기술정보통신부)의 재원으로 한국연구재단의 지원을 받아 수행된 연구임 (No. 2022R1F1A1074273).

REFERENCES

[1] “2022년 도로교통사고 사회적 비용,약 26조 2,833억원 발생 홈 > 소식·정보 > 알림마당 > 보도자료.” Accessed: Mar. 19, 2024. [Online]. Available: https://www.koroad.or.kr/main/board/6/89912/board_view.do?&cp=1&listType=list&bdOpenYn=Y&bdNoticeYn=N

[2] “국가지표체계 | 지표상세정보.” Accessed: Mar. 19, 2024. [Online]. Available: https://www.index.go.kr/unify/idx-info.do?idxCd=4261

[3] P. Trirat, S. Yoon, and J.-G. Lee, “MG-TAR: Multi-View Graph Convolutional Networks for Traffic Accident Risk Prediction,” *IEEE Transactions on Intelligent Transportation Systems*, pp. 1-16, Jan. 2023, doi: 10.1109/TITS.2023.3237072.

[4] Y. Yao, X. Zhao, Y. Wu, Y. Zhang, and J. Rong, “Clustering driver behavior using dynamic time warping and hidden Markov model,” *J Intell Transp Syst*, vol. 25, no. 3, pp. 249-262, 2021, doi: 10.1080/15472450.2019.1646132.

[5] Chen S, Cheng K, Yang J, Zang X, Luo Q, Li J. “Driving Behavior Risk Measurement and Cluster Analysis Driven by Vehicle Trajectory Data,” Applied Sciences. 2023; 13(9):5675. https://doi.org/10.3390/app13095675

[6] Driver Group Clustering Technique and Risk Estimation Method for Traffic Accident Prevention, 한국컴퓨터정보학회논문지, under review.

[7] 송용준. "CNN-LSTM 모델을 활용한 실시간 운전자 행위 식별 시스템." 국내석사학위논문 한양대학교 대학원, 2021. 서울

[8] 김형규, and 류승기. "MTCNN 기반 운전자 시선정보 시각화 연구." 디지털예술공학멀티미디어논문지 9.4 (2022): 431-440.

[9] 양지웅, 정현진, 이현진, 김태욱 and 홍정희. "운전자 이상행동 및 시선에 따른 교통사고 위험도 예측" 한국컴퓨터정보학회논문지 29, no.8 (2024): 1-9.

[10] “TAAS 교통사고분석시스템.” Accessed: Feb. 13, 2024. [Online]. Available: https://taas.koroad.or.kr/web/shp/sbm/initGisAnals.do?menuId=WEB_KMP_GIS_TAS

저자소개

김 태 욱 (Tae-Wook Kim)

2021년 3월~현 재 : 연세대학교 소프트웨어학부(재학)
관심분야 : Deep Learning, Computer Vision, Applied Artificial Intelligence

주 준 경 (Jun-Kyung Ju)

2022년 3월~현 재 : 연세대학교 소프트웨어학부(재학)
관심분야 : Deep Learning, Machine Learning, Computer Vision

신 효 승 (Hyo-Seung Shin)

2023년 3월~현 재 : 연세대학교 소프트웨어학부(재학)
관심분야 : Deep Learning, Robotics, Computer Vision

박 규 민 (Gue-Min Park)

2019년 3월~현 재 : 연세대학교 컴퓨터정보통신공학부(재학)
관심분야 : Deep Learning, Computer Vision, Back-End, Database

홍 정 희 (Ellen J. Hong)

2013년 2월 : KAIST 전기및전자공학과(공학박사)
2016년 10월~2018년 1월 : 동서대학교 컴퓨터공학부 조교수
2018년 2월~2019년 8월 : KT 융합기술원 선임연구원
2019년 9월~현재 : 연세대학교 소프트웨어학부 조교수
관심분야 : 인공지능, 시스템 모델링 시뮬레이션, 시뮬레이션 기반 최적화, 디지털 트윈, 지능형 시스템