

MoCo v3 및 객체 탐지 기반 교통사고 영상 분석

주준경¹, 신호승¹, 박규민², 김태욱³, 홍정희^{1*}

¹연세대학교 소프트웨어학부, ²대한변호사협회 IT부서, ³KAIST 산업및시스템공학과

Traffic Accident Video Analysis using MoCo v3 and Object Detection

Jun-Kyung Ju¹, Hyo-Seung Shin¹, Gyu-Min Park², Tae-Wook Kim³, Ellen J. Hong^{1*}

¹Department of Software, Yonsei University

²I. T. Division of Korean Bar Association

³Dept. of Industrial & Systems Engineering, KAIST

요약 매년 발생하는 교통사고는 막대한 사회적 비용과 인명 피해를 초래하므로, 효과적인 예방 대책 수립을 위해 교통사고의 원인과 특성을 체계적으로 분석하는 것이 중요하다. 기존 연구는 운전자 특성, 차량 가속도 센서, 차량 내부 시선 및 이상행동, 실시간 CCTV 영상 등 다양한 데이터를 활용하여 교통사고를 분석해 왔으나, 사고 상황에 대한 풍부한 정보를 포함하는 블랙박스 영상을 활용한 연구는 상대적으로 부족하다. 이에 본 연구는 객체 탐지 기반 필터링을 적용한 블랙박스 영상을 사용하여 교통사고 원인과 특징을 분석하였다. 이를 위해 MoCo v3 프레임워크와 Video Vision Transformer 기반 인코더를 이용해 영상 표현을 학습하고, 학습된 표현에 K-means 클러스터링을 적용하였다. 또한 영상별 라벨 데이터를 그룹화하고 adjusted Pearson residual을 사용하여 각 클러스터에서 상대적으로 두드러지는 사고 맥락을 분석하였다. 실험 결과, 총 8개의 클러스터가 도출되었으며, 시각적 패턴과 라벨 기반 정량 해석을 통해 각 클러스터의 특징을 확인하였다.

• **주제어** : 교통사고, 영상, 대조학습, MoCo v3, 객체 탐지, K-means

Abstract Traffic accidents cause substantial social costs and loss of life every year, making it important to systematically analyze their causes and characteristics in order to establish effective prevention strategies. Previous studies have analyzed traffic accidents using various data sources, including driver characteristics, vehicle accelerometer sensors, in-vehicle gaze and abnormal behavior, and real-time CCTV footage. However, studies using black box videos, which contain rich information about accident situations, remain relatively limited. In this study, we analyzed the causes and characteristics of traffic accidents using black box videos processed with object detection-based filtering. To this end, we learned video representations using the MoCo v3 framework and a Video Vision Transformer-based encoder, and then applied K-means clustering to the learned representations. In addition, we grouped video-level label data and used adjusted Pearson residuals to analyze accident contexts that were relatively prominent in each cluster. Experimental results identified eight clusters, and the characteristics of each cluster were confirmed through visual patterns and label-based quantitative interpretation.

• **Key Words** : Traffic Accident, Video, Contrastive Learning, MoCo v3, Object Detection, K-means

Received 28 January 2026, Accepted 27 April 2026

* **Corresponding Author** Ellen J. Hong, Department of Software, Yonsei University, 1, Yonseidaegil, Wonju, Gangwon-do, Korea.
Email: ellenhong@yonsei.ac.kr

I. Introduction

한국교통연구원 보도 자료[1]에 따르면, 2022년 도로 교통사고 비용은 43조 7,669억원이 발생하였다. 이는 국내 GDP의 2.0% 수준으로 미국, 독일, 영국보다 높은 것으로 나타났다. 위와 같은 개인과 국가의 비용을 감소시키기 위한 예방 대책을 마련하기 위해서는, 교통 사고 발생 원인과 특징을 분석하는 것이 중요하다.

기존에는 교통사고의 원인 분석을 위해서 운전자 특성[2], 차량의 가속계 센서[3], 차량 내부 운전자 시선 및 이상행동[4], 실시간 CCTV 영상[5,6] 등의 데이터를 기반으로 분석이 진행되었고, 이뿐만 아니라 운전자가 급하게 이동해야 하는 경우와 같은 시나리오 기반 교통사고 분석[7]이 수행되었다. 그러나 사고 직전 운전자의 시각적 상황에 따른 행동과 그에 따른 사고 유형을 함께 담고 있는 블랙박스 영상을 활용한 연구는 아직 부족하다. 블랙박스 영상은 사고 전후의 직접적인 시각적 맥락을 제공하지만, 영상으로부터 사고 관련 핵심 단서를 추출하고 서로 다른 사고 영상 사이의 공통 패턴을 식별해야 하므로 분석에 어려움이 존재한다. 최근 딥러닝 기술의 발전에 따라, 데이터 간의 유사도를 기반으로, 비슷한 데이터 간의 벡터 표현이 유사하도록 학습하는 대조학습[8,9]이 자기 지도 학습 분야에서 각광받고 있다. 다양한 상황에서 발생한 교통사고 영상 간의 공통점을 파악한다는 관점에서, 대조학습 기법은 교통사고 영상 기반 사고 원인 및 특징 분석에 적용할 수 있다.

따라서 본 논문에서는 1인칭 교통사고 블랙박스 영상에 대조학습을 적용하여 사고 원인과 특징을 분석하고자 한다. 이를 위해 차량과 신호등 중심의 객체 탐지 기반 필터링을 적용한 뒤, MoCo v3 프레임워크와 ViViT 기반 인코더를 사용하여 사고 영상의 표현 벡터를 학습하였다. 이어 학습된 표현 벡터에 K-means 클러스터링을 적용하여 잠재적 구조를 분석하고, 세분화된 라벨 카테고리를 상위 카테고리로 통합한 후 클러스터별 라벨 분포와 adjusted Pearson residual을 바탕으로 각 클러스터의 사고 맥락을 해석하였다.

II. Related Works

2.1 Traffic Accident Analysis

교통사고의 주된 원인은 운전자의 과실이다. 때문에, 운전자의 주행 특성, 인적 사항 등을 분석하고, 운전자 특성에 따라 발생하는 사고 분석은 중요하다. 사고일시, 도로 형태, 차종, 운전자 나이, 성별 등과 같은 운전자 특성 및 외부 요인들과 사고 유형, 교통사고 상해 정도, 가해자의 법규 위반 등과 같은 사고 특징 간의 관계를 연구한 [2]는 K-means 클러스터링과 통계 기반 전처리 기법을 통해 효과적인 교통사고 원인 분석 방법을 제안하였다. 운전자의 주행 특성과 사고 위험도 간의 관계를 분석한 [3]은 운전자의 주행 특징이 드러나는 차량 가속계 센서를 기반으로 4가지 지표를 제시 및 추출하였고, 추출된 지표들을 K-means 클러스터링을 사용하여 유사한 주행 특징을 지니는 운전자들을 클러스터로 형성하였다. 이후 각 운전자 집단에 대하여 공격적, 안정적, 보수적 운전자 집단으로 나누어 분석하는 방법을 제시하였다. 운전자의 이상행동과 시선에 따라 사고 위험도가 높아진다는 점에 집중한 [4]는 시선 벡터와 운전자의 이상행동을 실시간으로 추출하여 사고 위험도를 측정 및 분석하기 위한 프레임워크를 제시하였다. 이뿐만 아니라, 동일한 주행 특성을 가지는 운전자가 급하게 이동해야 하는 상황에 직면하였을 때 사고 위험 및 특징을 분석하는 연구도 진행되었다[7].

또한, 교통사고는 운전자 특성과 더불어서 주행 환경에 영향을 받아 발생할 수 있으므로, 다른 차량 간의 상호작용 및 외부 환경과 같은 차량 외부 요인들에 대한 분석도 중요하다. 차량 간의 움직임을 기반으로 사고가 발생할 가능성을 사전에 빠르게 탐지 및 대응하여 교통사고 피해를 감소시키기 위해서, 도로 CCTV 사고 영상 데이터셋에 대하여 차량들을 탐지하고 각 차량의 시간에 따른 경로들을 분석하여 교통사고를 탐지하는 연구가 수행되었다[5]. 비슷하게, 교통사고 가능성이 있는 비정상적인 차량 간 경로들을 분석하기 위해서, 도로 CCTV 영상을 사용하고 Dynamic Time Warping 기법을 적용하여 분석하는 연구가 진행되었다 [6].

2.2 Contrastive Learning Frameworks

대조학습은 비지도 표현학습을 위한 딥러닝 기법이다. 대조학습의 목적은 데이터의 표현을 학습하여, 유사한 데이터들이 표현 공간에서 가깝게 위치하고, 상이한 데이터들은 멀리 떨어지도록 하는 것이다. 대표

적인 대조학습 기법으로는 SimCLR[8], MoCo v3[9] 프레임워크가 존재한다. SimCLR은 하나의 데이터에 대해서 2가지 Random Augmentation을 적용하여 얻은 2가지 데이터를 인코더(encoder)에 입력하여 벡터 표현을 얻었을 때, 두 벡터 표현의 코사인 유사도가 높은 방향으로 학습하는 방식이다. 이때, Random Augmentation은 Random Cropping, Random Gaussian Blur, Random Color Distortions 등으로 구성된 과정을 의미한다. 하지만, SimCLR 기법은 학습 과정에서 인코더의 벡터 표현이 변화함에 따라 이전 학습 데이터들의 벡터 표현과 일관성이 유지되지 않는다는 문제가 존재하였다. 때문에, 프레임워크는 단순하나 Batch-Size가 크고 많은 Epoch 동안 학습하지 않으면 인코더의 벡터 표현 품질이 떨어지게 된다.

이러한 일관성 문제를 해결하기 위해서 MoCo 계열의 프레임워크[9]는 SimCLR과 비슷한 Augmentation 방법과 더불어 2개의 인코더인 Query 인코더와 Momentum 인코더를 사용하는 것을 제안하였다. 특히, Momentum 인코더는 급격한 변화가 발생하는 Query 인코더의 가중치들에 대한 이동평균선과 같은 역할을 수행하여 학습 과정 중 데이터들의 벡터 표현에 대해 일관성을 최대한 유지하면서 대조학습의 목적을 달성할 수 있도록 설계되었다.

따라서, 본 논문은 보다 안정적인 학습을 위해서 MoCo v3 프레임워크를 사용하였으며, 자세한 내용은 3장에서 다룬다.

2.3 Contrastive Learning Applied to Video

대조학습을 비디오 데이터에 학습하기 위한 다양한 연구들이 진행되었다. 예를 들어, 비디오 Augmentation 과정에서 각 이미지에 대해 강한 Random Augmentation을 적용하는 Spatial Augmentation과 영상 내의 프레임들에 대해서 Sampling을 수행하는 Temporal Augmentation을 사용하여 영상에 대한 효과적인 대조학습 방법에 관한 연구가 진행되었다[10]. 하지만, 위와 같은 방식은 영상 내의 배경과 움직이는 물체를 포함하는 모든 정보를 기반으로 유사한 영상은 유사한 벡터로 표현되도록 모델이 학습된다. 이는, 차량 간의 상호작용이나 신호등과 같은 특정 물체들이 아닌 배경과 같은 교통사고와 무관하거나 영향력이 낮은 요인들에 의해서 유사하다고 판단되도록 모델이 학습될 가능성이 있다.

위와 같은 문제점을 해결하기 위해서, 영상 내의 움직이는 물체만을 푸리에 변환 및 주파수 필터링하여 대조학습에 활용하는 연구도 제안되었다[11]. 해당 연구에서는 주로 고정적인 배경 위의 움직이는 물체에 대해서 효과적으로 분리한 뒤 대조학습을 수행함으로써 유의미한 성능을 보였다. 그러나, 본 논문에서 사용되는 블랙박스 교통사고 영상은 차량의 이동에 따라 물체뿐만 아니라 배경도 함께 크게 변화하므로, 주파수 기반 필터링만으로는 차량이나 신호등과 같은 사고 유발에 영향을 미칠 수 있는 객체에 선택적으로 학습을 집중시키는 데 한계가 있다. 따라서 본 논문에서는 사고 장면 해석에 중요한 객체를 중심으로 영상 표현을 학습할 수 있도록 객체 탐지 기반 필터링을 적용하며, 이에 대한 구체적인 구성은 3장에서 설명한다. 나아가 본 논문은 학습된 영상 표현 벡터를 단순히 시각화하는 데 그치지 않고, 데이터셋 라벨 정보와 결합한 라벨 기반 정량 해석을 통해 각 클러스터의 의미를 후속적으로 분석한다는 점에서 기존 연구와 구별된다.

III. The Proposed Scheme

3.1 Dataset Construction

이 절에서는 대조학습을 위한 데이터셋 구축과정에 사용되는 교통사고 영상, 필터링 방법, 전처리 방법에 대해 설명하며 전체적인 과정은 Fig. 1과 같다.

3.1.1 Traffic Accident Black Box Video Dataset

본 논문에서는 AIHub에서 제공하는 교통사고 영상 데이터셋[12]을 바탕으로 교통사고 원인 및 특징을 분석하고자 한다. 해당 데이터셋은 차대차 및 차대보행자와 같은 사고 대상, 직선도로, 횡단보도와 같은 사고 장소, 가해자와 피해자의 과실 비율 등 다양한 기준에 따라 분류된 14,212개의 사고 영상과 라벨로 구성되어 있다. 이 중 가해자의 과실 비율과 관계 없이 차대차 교통사고 영상만을 사용하여 데이터셋을 구축한다. 데이터셋 구축 과정에서는 먼저 메타데이터 기준으로 filming_way가 bb이고 video_point_of_view가 1인 1인칭 블랙박스 영상을 대상으로 하였으며, 이후 10초 미만 영상은 제외하였다. 차대차 영상 중 88%는 1920×1080 또는 1920×926 해상도를 가지는 것으로




Fig. 1. Overview of (a) Dataset Construction and (b) Example of Object Detection-Based Filtering Results

확인되었다. 이에 본 연구에서는 데이터 분포에서 가장 높은 비중을 차지하는 해상도를 기준 해상도로 설정하였고 입력 형상의 일관성 확보 및 후속 영상 처리의 안정성을 위해 모든 영상의 해상도를 1920×1080으로 통일하였다.

AIHub 교통사고 영상 데이터는 사고 시점을 기준으로 전후 5초, 총 10초 구간으로 정제되어 제공된다. 본 논문에서는 충돌 이전의 접근 상황과 충돌 직후의 결과를 모두 반영하기 위해 각 영상의 전체 10초 구간을 활용하였다. 다만 실제 영상들은 초당 프레임 수와 총 프레임 수가 서로 다르므로, 입력 데이터의 시간적 형상을 일관되게 맞추기 위해 각 영상에서 균등한 시간 간격으로 16개의 프레임을 추출하였다. 또한 8프레임 구성은 시간적 문맥을 충분히 반영하지 못했고, 32프레임 구성은 본 연구의 학습 환경에서 메모리와 연산 부담이 커 안정적인 실험 수행이 어려웠다. 이에 시간적 맥락 보존과 계산 효율을 함께 고려하여 16프레임 구성을 최종적으로 사용하였다.

3.1.2 Object Detection-based Filtering

본 절에서는 2.3절의 문제의식을 바탕으로 객체 탐지 기반 필터링의 구체적 적용 방법을 설명한다. 일반적인 비디오 대조학습은 배경과 움직이는 물체를 모두 포함한 시각 정보를 학습하므로, 블랙박스 영상에서는 차량 간 상호작용이나 교통 제어 요소보다 촬영 장소, 조명, 건물, 하늘과 같은 배경 정보에 의해 유사성이 형성될 수 있다. 실제로 사고 상황 자체보다 배경의 명암이나 장면 분위기에 따라 군집이 형성되는 사례가 관찰되었으며, 후방추돌과 같은 사고 유형은 촬영 지역이 달라지더라도 차량 간 상대 위치와 접근 양상 등 객체 중심 정보에 의해 설명되는 경우가 많았다. 이에 본 논문에서는 3.1.1에서 구축한 데이터셋의 각 프레임에 객체 탐지 기반 필터링을 적용하여, 배경보다 도로 위 사고 관련 객체에 표현학습이 집중되도록 하였다.

객체 탐지 모델은 COCO 2017 object detection dataset으로 사전 학습된 DETR 모델[13]을 사용하였다. 본 논문에서는 우선적으로 차량과 신호등에 대해서 객

체 탐지를 수행하였으며, 구현 시에는 car, truck, bus, traffic light 범주에 해당하는 객체가 검출된 영역만을 유지하고 나머지 영역은 제거하는 방식으로 필터링을 적용하였다. 이를 통해 사고 장면의 본질적인 상호작용을 보다 잘 반영하는 표현을 학습하고자 하였다. 다만 이러한 필터링은 사고 장소나 주행 상태를 설명하는 일부 배경 맥락 정보를 약화시킬 수 있으므로, 이에 따른 해석상의 한계는 이후 라벨 기반 정량 분석 및 실패 사례 분석에서 함께 논의한다.

이상의 과정을 통해 원본 블랙박스 사고 영상으로부터 자기지도 학습에 사용되는 최종 데이터셋을 구축하였다. 데이터셋 구축 과정의 각 단계와 단계별 잔여 영상 수는 Table 1.에 정리하였다.

3.1.3 Preprocessing Method

Table 1. Stepwise Construction of the Traffic Accident Black Box Video Dataset

Stage	Selection/Processing Criterion	Number of Videos
Raw extracted video set	Vehicle-to-vehicle accident video clips extracted from the source dataset	14,212
Metadata-validated subset	Verified to satisfy filming_way = bb and video_point_of_view = 1	14,212
Temporally validated subset	Video duration of at least 10 seconds	14,195
Spatially standardized subset	Resolution normalized to 1920x1080 with valid frame count verification	14,195
Object-aware filtered subset	DETR-based object filtering successfully applied to all frames	14,195
Final dataset for SSL training	Videos used for self-supervised contrastive learning	14,195

3.1.1, 3.1.2 절의 과정을 거쳐 객체 탐지 기반 필터링이 적용된 각 영상들의 해상도는 1920×1080이다. 그러나 고해상도 영상을 그대로 사용할 경우 입력 차원이 커져 연산 비용과 메모리 부담이 증가하고, 학습

효율 또한 저하될 수 있다. 이에 본 논문에서는 모든 영상을 224×224 해상도로 재조정하여 입력 크기를 통일하였으며, 각 영상의 RGB 값에 대하여 식 (1)과 같이 Min-Max Scaling을 적용해 0과 1 사이의 값으로 정규화하였다.

$$X_{scaled} = \frac{X - X_{min}}{X_{max} - X_{min}} \quad (1)$$

3.2 Contrastive Learning

2.2 절에서 언급된 바와 같이, 본 논문에서는 MoCo v3 프레임워크를 사용하여 대조학습을 진행한다. MoCo v3는 동일한 구조를 가지는 2개의 인코더 f_q, f_k 를 사용한다. 본 논문에서는 인코더로 비디오 데이터에 효과적으로 학습할 수 있는 Video Vision Transformer (ViViT)[14]를 사용한다. 이 과정에서 두 인코더의 초기 가중치는 동일하다.

데이터셋으로부터 Batch Size N 개의 비디오 데이터가 주어졌을 때, 각 데이터 $x_i \in \mathbb{R}^{16 \times 224 \times 224 \times 3}$ 에 Random Augmentation을 적용하는 과정을 2번 반복하여 $x_{i,1}, x_{i,2}$ 를 얻는다. 이때 i 는 N 개의 데이터 내의 데이터 번호를 의미한다. 이후, $x_{i,1}, x_{i,2}$ 각각에 대하여 인코더 f_q, f_k 를 통해 식 (2)와 같이 벡터를 추출한다.

$$\begin{aligned} f_q(x_{i,j}) &= q_{i,j} \\ f_k(x_{i,j}) &= k_{i,j} \end{aligned} \quad (2)$$

where $j \in \{1, 2\}, i \in \{1, 2, \dots, N\}$

추출된 벡터들에 대해서 식 (3)의 손실함수를 기반으로 인코더 f_q 의 가중치만 역전과 과정을 통해 학습한다.

$$\begin{aligned} L(q, k) &= L_{Info}(q_{:,1}, k_{:,2}) + L_{Info}(q_{:,2}, k_{:,1}) \\ L_{Info}(q_{:,a}, k_{:,b}) &= - \sum_{i=1}^N \log \frac{e^{\text{sim}(q_{i,a}, k_{i,b})/\tau}}{\sum_{j=1}^N e^{\text{sim}(q_{i,a}, k_{j,b})/\tau}} \end{aligned} \quad (3)$$

where $a, b \in \{1, 2\}, a \neq b$,
sim() is cosine similarity

Table 2. Summary of labels used for quantitative interpretation and grouping rules

Label	Meaning	Grouping Rule
accident_place	Spatial context of the accident scene	Grouped into coarse categories based on road-space context
accident_place_feature	Detailed characteristics of accident interaction and road structure	Grouped into coarse categories based on accident interaction and road structure cues
vehicle_a_progress_info	Movement and maneuver information of vehicle A	Grouped into coarse categories based on the maneuver type of vehicle A
vehicle_b_progress_info	Movement and maneuver information of vehicle B	Used only as an auxiliary criterion for exploratory comparison

마지막으로 인코더 f_k 를 구성하는 가중치들에 m 을 곱하고, 학습 과정을 통해 변환된 인코더 f_q 의 가중치들에 $1-m$ 을 곱한 뒤, 두 가중치를 더한 결과를 인코더 f_k 의 가중치로 갱신한다.

위 과정을 반복하여, 유사한 비디오 데이터들의 벡터 간 코사인 유사도가 높고, 비슷하지 않은 비디오 데이터들의 벡터 간 코사인 유사도가 낮도록 학습된 인코더 f_q 를 사용하여 이후의 분석을 진행한다.

3.3 K-means Clustering and Analysis

학습된 인코더 f_q 를 사용하여 전체 영상을 표현 벡터로 변환한 뒤, K-means 클러스터링을 수행하였다. 클러스터 수는 2부터 20까지 변화시키며 silhouette score를 비교하였고, 그 값이 가장 높으면서 클러스터 수가 상대적으로 적은 경우를 최적 설정으로 선택하였다. 이후 UMAP[15]으로 분포를 시각화하고 각 클러스터 중심과의 코사인 유사도가 가장 높은 대표 영상을 추출하여 시각적 특성을 확인하였다. 아울러 클러스터 할당 결과를 라벨 정보와 결합하여, 상위 카테고리 통합된 라벨 분포와 adjusted Pearson residual을 바탕으로 라벨 기반 정량 해석을 수행하였다. 또한 동일한 데이터셋과 클러스터링 설정에서 MoCo v3, SimCLR과 ViViT, C3D[16], X3D[17]를 교차 조합하여 silhouette score와 UMAP 분포를 비교하였다.

3.4 Label-based Cluster Interpretation Procedure

클러스터 해석의 객관성을 보완하기 위해, 대조학습 및 K-means 클러스터링 결과를 원본 라벨 정보와 결합하여 라벨 기반 정량적 분석을 수행하였다. 구체적으로 각 영상들의 클러스터 할당 결과와 함께 accident_place,

accident_place_feature, vehicle_a_progress_info를 주요 분석 대상으로 사용하였으며, vehicle_b_progress_info는 필요 시 보조적으로만 참고하였다.

그러나 원본 라벨 정보는 세분화된 라벨 카테고리 구성되어 있어, 각 카테고리를 그대로 사용할 경우 분포가 지나치게 희소해지고 클러스터 간 비교가 불안정해질 수 있다. 이에 본 논문에서는 의미상으로 유사한 세부 라벨들을 상위 카테고리로 통합하여 해석 단위를 재구성하였다. 이러한 그룹화는 클러스터 분포 비교를 더욱 안정적으로 수행하고, 각 라벨이 반영하는 사고 맥락을 상위 수준에서 해석하기 위해 적용하였다. 사용된 라벨의 의미와 그룹화 기준은 Table 2에 정리하였다. 이를 바탕으로 먼저 각 클러스터 내부에서 상위 카테고리의 분포를 집계하여 단일 범주 분포 분석을 수행하였다.

그러나 단순 빈도 또는 비율 기반 분포는 전체 데이터셋에서 자주 등장하는 상위 카테고리가 여러 클러스터에서 공통으로 높게 나타나는 경향이 있어, 각 클러스터의 특징을 직접적으로 드러내는 데 한계가 있다. 따라서 본 논문에서는 전체 분포와 주변 합의를 영향을 보정한 상태에서 각 클러스터에서 상대적으로 과대 표현되거나 과소 표현되는 상위 카테고리를 평가하기 위해 adjusted Pearson residual 분석을 추가로 수행하였다.[18,19]

전체 표본 수를 N 개, 클러스터 i 와 상위 카테고리 j 에 대한 관측 빈도를 O_{ij} , 기대 빈도를 E_{ij} 라 할 때, 기대 빈도는 식 (4)와 같이 계산하였다.

$$E_{ij} = \frac{(\sum_j O_{ij})(\sum_i O_{ij})}{N} \quad (4)$$

또한, 행과 열 비율을 식 (5)와 같이 정의한다.

$$p_{i.} = \frac{\sum_j O_{ij}}{N}, \quad p_{.j} = \frac{\sum_i O_{ij}}{N} \quad (5)$$

이후, adjusted residual은 식 (6)와 같이 기대 빈도뿐 아니라 행과 열의 주변합에 따른 영향을 추가로 보정하여 계산하였다.[19]

$$R_{ij} = \frac{O_{ij} - E_{ij}}{\sqrt{E_{ij}(1 - p_{i.})(1 - p_{.j})}} \quad (6)$$

여기서 R_{ij} 가 양수이고 클수록 해당 상위 카테고리 가 클러스터 i 에서 전체 분포 대비 상대적으로 더 많이 나타남을 의미하며, 음수일 경우에는 상대적으로 덜 나타남을 의미한다. 본 논문에서는 잔차의 상대적 크기를 이용하여 각 클러스터에서 두드러진 상위 카테고리를 선정하고, 이를 바탕으로 클러스터 해석 테이블을 구성하였다.

보조적으로 상위 카테고리 간 조합 패턴을 확인하기 위한 2개 이상의 범주 분포 분석도 수행하였으나, 클러스터를 직접적으로 구분하는 특성을 식별하는 데에는 adjusted residual 기반 단일 범주 분포 분석이 더 효과적이었으므로 본문에서는 이를 중심으로 기술한다.

3.5 Implementation Details

전체 데이터셋 구축 및 학습 과정은 PyTorch 라이브러리를 사용하여 구현하였다. 대조학습 과정에서 사용된 Random Augmentation은 RandomResizedCrop, ColorJitter, RandomGrayscale, RandomGaussianBlur 총 4가지로 PyTorchVideo 라이브러리에서 제공하는 RandAugment를 활용하여 적용하였다. 인코더 f_q , f_k 를 학습하기 위한 파라미터 m 은 0.99로, τ 는 0.7로 설정하였다. Batch Size N 은 32, Epoch는 100으로 설정하였으며, AdamW(lr=1e-4) Optimizer를 사용하여 학습하였다. 클러스터링의 경우, scikit-learn 라이브러리의 K-means(max_iter=1000, init='k-means++', n_init=10)를 사용하여 구현하였다. 비교 실험에서는 데이터셋, 프레임 수, 입력 해상도, Augmentation, Optimizer, Epoch,

Clustering 설정 등을 동일하게 유지한 상태에서 SSL 프레임워크와 인코더 Backbone만 변경하였다.

IV. Experiments

4.1 Comparative Evaluation of SSL Frameworks and Video Encoders

본 논문에서 제안하는 방법론의 우수성을 더욱 객관적으로 검증하기 위해, SSL 프레임워크(MoCo v3, SimCLR)와 영상 인코더(ViViT, C3D, X3D)를 교차 조합한 비교 실험을 수행하였다. 모든 실험은 동일한 데이터셋, 프레임 구성, 입력 해상도, augmentation, optimizer 및 K-means 클러스터링 파라미터로 수행되었으며, 2~20개의 클러스터 후보 중 silhouette score가 가장 높은 경우를 각 조합의 최적 설정으로 선택하였다.

Table 3.에서 볼 수 있듯이, MoCo v3는 모든 인코더 조합에서 SimCLR보다 높은 silhouette score를 기록하였다. 이는 momentum 인코더를 사용하는 MoCo v3가 교통사고 영상의 표현 공간을 보다 안정적으로 형성함을 시사한다. 특히 ViViT를 인코더로 사용한 경우 MoCo v3는 8개 클러스터에서 0.802의 silhouette score를 보여, C3D 기반 MoCo v3(4개, 0.593)보다 우수한 클러스터링 구조를 형성하였다.

한편 MoCo v3 + X3D는 0.978의 가장 높은 silhouette score를 보였으나, 최적 클러스터 수가 2에 그쳤다. 이는 데이터셋을 거시적 수준에서 분리하는 데에는 효과적일 수 있으나, 다양한 사고 패턴을 세분화하여 분석하는 본 연구의 목적에는 부적합함을 의미한다. 실제 UMAP 시각화에서도 MoCo v3 + X3D는 2개 군집으로 요약되지만 군집 내부 구조가 불안정하고 해석 가능성이 낮은 경향을 보였다. 반면 MoCo v3 + ViViT는 비교적 높은 silhouette score를 유지하면서도 8개의 군집을 형성하여, 군집 품질과 세분화 수준 사이에서 가장 균형적인 결과를 보였다.

따라서 이후의 클러스터 수 선택, UMAP 시각화, 라벨 기반 정량 분석, 대표 영상 분석, 실패 사례 분석은 모두 MoCo v3 + ViViT 설정을 기준으로 수행하였다.

Table 3. Quantitative comparison of SSL frameworks and video encoders using the best number of clusters and silhouette score

SSL	Encoder	Best number of clusters	Silhouette Score
MoCo v3	ViT	8	0.802
MoCo v3	C3D	4	0.593
MoCo v3	X3D	2	0.978
SimCLR	ViT	11	0.490
SimCLR	C3D	9	0.414
SimCLR	X3D	13	0.434




Fig. 2. Silhouette Score for Each Number of Clusters

4.2 Cluster Number Selection based on Silhouette Score

대조학습을 통해 학습된 영상 표현 벡터에 K-means 클러스터링을 적용하고, 클러스터 수를 변화시키며 각 경우의 silhouette score를 비교하였다. 그 결과는 Fig. 2와 같다.

4.3 Comparative UMAP Visualization

Table 3.의 정량 비교 결과를 보완하기 위해, 주요 SSL-인코더 조합의 표현 벡터 분포를 Fig. 3과 같이

UMAP으로 시각화하였다. MoCo v3 + ViViT는 비교적 뚜렷한 다중 군집 구조를 형성하였으며, 일부 군집은 2차원 공간상에서 독립적으로 분리되어 나타났다. 이는 8개의 클러스터를 유지하면서도 높은 silhouette score를 기록한 정량 결과와 일치한다.

반면, SimCLR + ViViT는 전체 분포가 하나의 큰 응집 영역처럼 나타나 군집 간 중첩이 크게 관찰되었다. 한편 MoCo v3 + X3D는 가장 높은 silhouette score를 보였지만 최적 클러스터 수가 2에 그쳤고, UMAP 상에서도 세분화된 패턴 분석보다는 거시적 군집화에 가까운 구조를 보였다. 종합하면, MoCo v3 + ViViT는 높은 군집 품질과 충분한 세분화 수준을 동시에 제공하는 가장 균형적인 조합으로 판단된다. 이러한 표현 벡터 분포가 실제로 어떤 사고 맥락과 대응되는지는, 원본 라벨 정보를 이용한 라벨 기반 정량 해석을 통해 추가로 검토하였다.

4.4 Label-based Quantitative Interpretation using Coarse Categories and Adjusted Residuals

클러스터 할당 결과에 accident_place, accident_place_feature, vehicle_a_progress_info의 상위 카테고리 정보를 결합하여 라벨 기반 정량 해석을 수행하였다. 세분화된 라벨 카테고리는 의미적으로 유사한 상위 카테고리로 통합하였으며, 먼저 각 클러스터의 상위 카테고리 분포를 집계하여 전반적 경향을 확인한 뒤 adjusted Pearson residual을 이용해 전체 분포 대비 상대적으로 두드러진 사고 맥락을 식별하였다.

Fig. 4의 단일 범주 히트맵에서는 여러 클러스터에 공통적으로 높은 상위 카테고리가 반복적으로 나타났다. 이는 전체 데이터셋에서 자주 등장하는 사고 맥락이 여러 클러스터에 동시에 반영되었음을 의미하며, 단순 비율 기반 분포만으로는 각 클러스터의 특징을 명확히 식별하기 어렵다는 점을 보여준다. 이 한계를 보완하기 위해 3.4절에서 정의한 adjusted residual을 사용하여 각 클러스터에서 기대 빈도 대비 상대적으로 두드러진 상위 카테고리를 계산하였다. Fig. 5는 그 결과를 보여주며, 전체적으로 자주 등장하는 카테고리의 영향을 줄인 상태에서 클러스터를 구분하는 사고 맥락을 식별할 수 있음을 확인하였다. 즉, 단일 범주 분포 분석이 공통적인 사고 맥락을 보여주는 기초 분석이라면, adjusted residual 분석은 각 클러스터를 구분하는




Fig. 3. Comparative UMAP visualization of major SSL-encoder combinations:
(a) MoCo v3 + ViViT, (b) SimCLR + ViViT, (c) MoCo v3 + X3D




Fig. 4. First-order heatmaps of coarse category distributions across clusters:

(a) accident place, (b) accident place feature, (c) vehicle a progress info, and (d) vehicle b progress info

상위 카테고리를 식별하는 핵심 분석으로 활용되었다.

Table 4는 adjusted residual이 큰 상위 카테고리를 중심으로 각 클러스터의 주요 사고 맥락을 정리한 결과이다. 사거리교차로(신호등 있음), 좌/우회전, 차도 외/비도로 공간, 정차 후 출발 사고, 상대 차량 진입과 같은 상위 카테고리는 클러스터마다 서로 다른 조합으

로 나타났으며, 이는 대표 영상 중심의 정성 해석을 라벨 기반 분포 분석으로 보완한다. 상위 카테고리 간 조합 패턴도 함께 검토하였으나, 클러스터를 직접적으로 구분하는 특성은 adjusted residual 기반 단일 범주 분석에서 가장 명확하게 확인되었으므로 본문에서는 그 결과를 중심으로 제시한다.




Fig. 5. Adjusted residual heatmaps for cluster-distinctive coarse categories: (a) accident place, (b) accident place feature, (c) vehicle a progress info, and (d) vehicle b progress info

Table 4. Cluster Interpretation based on Dominant Coarse Categories and Adjusted Residuals

Cluster	Dominant coarse categories	Interpretation
Cluster 0	accident_place: 2 accident_place_feature: 6, 16 vehicle_a_progress_info : 4	An interaction-heavy collision pattern involving lane or route changes around signalized intersections.
Cluster 1	accident_place_feature: 0, 3, 4, 18	A collision pattern characterized by rear-end impact and abnormal driving direction under constrained road structure.
Cluster 2	accident_place: 4 accident_place_feature: 2, 7, 8, 17	A low-speed contact pattern involving stopped-contact and counterpart entry in non-road or boundary-space contexts.
Cluster 3	accident_place_feature: 1, 3, 4, 13, 18	A compound collision pattern associated with merging, lane reduction, and turning under changing road structure.
Cluster 4	accident_place: 4 accident_place_feature: 0, 2, 17	A low-speed interaction pattern in non-road or boundary spaces, involving counterpart vehicle entry and contact.
Cluster 5	accident_place: 4 accident_place_feature: 0, 2, 8, 17	A boundary-space interaction pattern characterized by start-after-stop behavior.
Cluster 6	accident_place: 2 accident_place_feature: 1, 13, 14, 15	A structurally constrained collision pattern involving signalized intersections and turn-related rule violations.
Cluster 7	accident_place: 4 accident_place_feature: 0, 3, 12, 17	A compound collision pattern combining abnormal driving direction and counterpart vehicle entry.

4.5 Analysis of Representative Videos

4.4절의 라벨 기반 정량 해석 결과가 실제 시각적 장면 패턴과 정합적인지 확인하기 위해, 각 클러스터 중심과 가장 가까운 대표 영상들을 추가로 검토하였다. 분석 결과, adjusted residual을 통해 도출된 주요 상위 카테고리는 대표 영상들에서 관찰되는 주요 사고 맥락과 대체로 일관된 경향을 보였다. 예를 들어 클러스터 2와 클러스터 5에서는 차도 외/비도로 공간에서의 접촉, 상대 차량 진입, 정차 후 출발과 같은 장면이 반복적으로 관찰되었으며, 클러스터 6에서는 신호 교차로와 회전 또는 방향 전환이 개입된 장면이 상대적으로 뚜렷하게 나타났다. 이는 라벨 기반 정량 해석이 단순한 빈도 요약을 넘어, 실제 사고 장면의 시각적 패턴과도 일정 부분 대응함을 보여준다.

4.6 Failure Case Analysis

라벨 기반 분포 분석만으로 설명되지 않는 클러스터 차이의 원인을 확인하기 위해, 하위 유사도 샘플을 대상으로 실패 사례 분석을 수행하였다. 분석 결과, 표현학습과 클러스터링에 어려움을 주는 주요 조건은 사고 유형의 차이 자체보다 사고 관련 객체의 시각적 식별 가능성이 크게 저하되는 상황과 더 밀접하게 관련되어 있었다. 구체적으로 지나치게 어두운 장면, 과도한 대비, 뿌연 시야, 전면 유리 반사, 비정상적인 시야각으로 인해 차량 또는 충돌 객체의 윤곽이 명확히 드러나지 않는 경우와, 충돌이 매우 약하거나 사고 객체가 화면 내에서 매우 작은 영역만 차지하는 경우가 대표적으로 관찰되었다. 특히 상위 유사도 사례의 야간 영상은 가로등이나 전조등 등에 의해 객체 식별이 가능했던 반면, 하위 유사도 사례는 육안으로도 객체 분간이 어려운 수준의 저가시성을 보였다. 이는 단순한 저조도 자체보다 사고 관련 객체를 구분할 수 있을 만큼의 시각적 단서가 유지되는지가 표현학습 품질에 더 직접적인 영향을 미침을 시사한다.

V. Conclusions

본 논문은 객체 탐지 기반 필터링이 적용된 1인칭 블랙박스 교통사고 영상을 대상으로, MoCo v3와 ViViT 기반 자기지도 표현학습 및 K-means 클러스터링을 활용한 사고 패턴 분석 방법을 제안하였다. 비교 실험 결과, MoCo v3 + ViViT 조합은 클러스터링 품질과 세

분화 수준 측면에서 가장 균형적인 결과를 보였으며, UMAP 시각화에서도 다른 조합에 비해 비교적 뚜렷한 다중 군집 구조를 형성하였다. 또한 라벨 기반 정량 해석 결과, 단일 범주 분포 분석은 여러 클러스터에 공통적으로 나타나는 사고 맥락을 보여주었고, adjusted residual 분석은 전체 분포의 영향을 보정한 상태에서 각 클러스터를 구분하는 상위 카테고리를 식별하는 데 효과적이었다. 대표 영상 분석 역시 이러한 정량 해석이 실제 시각적 장면 패턴과 일정 부분 대응함을 뒷받침하였다.

한편 실패 사례 분석에서는 저가시성, 반사, 작은 객체 크기와 같이 사고 관련 객체의 식별 가능성이 낮은 조건이 표현학습 성능을 저하시킬 수 있음을 확인하였다. 향후에는 배경 맥락과 객체 중심 정보를 함께 반영하되, 배경 정보만으로 군집이 형성되지 않도록 하는 필터링 전략과 더욱 세분화된 라벨 체계를 도입할 필요가 있다.

ACKNOWLEDGMENTS

본 논문은 과학기술정보통신부의 재원으로 한국연구재단의 지원을 받아 수행된 연구임 (No.2022R1F1A1074273)

REFERENCES

- [1] Korea Transport Institute(KOTI), “[Press Release] 2022 Road Traffic Accident Costs Total 43.7 Trillion Won, a Slight 0.7% Decrease from the Previous Year”, Accessed: Feb. 18, 2025. [Online]. Available :https://www.koti.re.kr/user/bbs/noticeView.do?bbs_no=66018
- [2] Tae-Wook Kim, Ji-Woong Yang, Hyeon-Jin Jung, Han-Jin Lee, and Ellen J. Hong, Driver Group Clustering Technique and Risk Estimation Method for Traffic Accident Prevention, Journal of The Korea Society of Computer and Information, vol. 29, no. 8, pp. 53-58, 2024.
- [3] S. Chen, K. Cheng, J. Yang, X. Zang, Q. Luo, and J. Li, “Driving Behavior Risk Measurement and Cluster Analysis Driven by Vehicle Trajectory Data” Applied Sciences(Switzerland), vol. 13, no. 9, 2023.
- [4] Ji-Woong Yang, Hyeon-Jin Jung, Han-Jin Lee, Tae-Wook Kim and Ellen J. Hong. “Predicting Traffic

- Accident Risk based on Driver Abnormal Behavior and Gaze“ Journal of The Korea Society of Computer and Information 29, no.8, 2024.
- [5] A. P and G. Nallasivan, “A Vision-Based Traffic Accident Analysis and Tracking system from Traffic Surveillance Video,” 2024 Third International Conference on Intelligent Techniques in Control, Optimization and Signal Processing (INCOS), Krishnankoil, Virudhunagar district, Tamil Nadu, India, 2024.
- [6] A. Abdari, H. Mohammadzade and S. A. Hashemian, “Trajectory Clustering in Surveillance Videos Using Dynamic Time Warping,” 2021 7th International Conference on Signal Processing and Intelligent Systems (ICSPIS), Tehran, Iran, Islamic Republic of, 2021.
- [7] Q. Hussain and W. K. M. Alhajyaseen, “Driving against the clock: Investigating the impacts of time pressure on taxi and non-professional drivers’ safety and compliance,” Accident Analysis & Prevention, vol. 210. Elsevier BV, p. 107864, Feb. 2025.
- [8] Chen, Ting, et al. “A simple framework for contrastive learning of visual representations.” International conference on machine learning. PMLR, 2020.
- [9] X. Chen, S. Xie and K. He, “An Empirical Study of Training Self-Supervised Vision Transformers,” 2021 IEEE/CVF International Conference on Computer Vision (ICCV), Montreal, QC, Canada, 2021.
- [10] Qian, R., Meng, T., Gong, B., Yang, M.-H., Wang, H., Belongie, S., & Cui, Y. “Spatiotemporal Contrastive Video Representation Learning” , IEEE/CVF Conference on Computer Vision and Pattern Recognition, 2021.
- [11] J. Kim, T. Kim, M. Shim, D. Han, D. Wee, and J. Kim, “Frequency Selective Augmentation for Video Representation Learning,” Proceedings of the AAAI Conference on Artificial Intelligence, vol. 37, no. 1. Association for the Advancement of Artificial Intelligence (AAAI), pp. 1124-1132, Jun. 26, 2023.
- [12] AIHub, “Traffic Accident Video Data” , Accessed: Feb. 18, 2025. [Online]. Available : <https://www.aihub.or.kr/aihubdata/data/view.do?currMenu=115&topMenu=100&dataSetSn=597>
- [13] Huggingface. “DETR (End-to-End Object Detection) model with ResNet-50 backbone” , Accessed: Feb. 18, 2025. [Online]. Available : <https://huggingface.co/facebook/detr-resnet-50>
- [14] A. Arnab, M. Dehghani, G. Heigold, C. Sun, M. Lučić and C. Schmid, “ViViT: A Video Vision Transformer,” 2021 IEEE/CVF International Conference on Computer Vision (ICCV), Montreal, QC, Canada, 2021.
- [15] L. McInnes, J. Healy, and J. Melville, “UMAP: Uniform Manifold Approximation and Projection for Dimension Reduction,” 2018.
- [16] D. Tran, L. D. Bourdev, R. Fergus, L. Torresani, and M. Paluri, “Learning Spatiotemporal Features with 3D Convolutional Networks” , Proceedings of the IEEE International Conference on Computer Vision (ICCV), pp. 4489-4497, 2015.
- [17] C. Feichtenhofer, “X3D: Expanding Architectures for Efficient Video Recognition” , Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR), pp. 203-213, 2020.
- [18] S. J. Haberman, “The Analysis of Residuals in Cross-Classified Tables,” Biometrics, vol. 29, no. 1, pp. 205-220, 1973.
- [19] A. Agresti, An Introduction to Categorical Data Analysis, 2nd ed., New York: John Wiley & Sons, 2007.

저자소개

주 준 경 (Jun-Kyung Ju)



2022년 3월~현재 : 연세대학교
소프트웨어학부
관심분야 : Deep Learning,
Machine Learning, Computer
Vision, Simulation

신 효 승 (Hyo-Seung Shin)



2023년 3월~현재 : 연세대학교
소프트웨어학부
관심분야 : Deep Learning, Video
Coding, Computer Vision

박 규 민 (Gyu-Min Park)



2025년 8월 : 연세대학교
컴퓨터공학과(공학사)
2025년 9월~현재 :
대한변호사협회 IT부서
관심분야 : Deep Learning,
Computer Vision, Databases

김 태 욱 (Tae-Wook Kim)



2025년 2월 : 연세대학교
소프트웨어학부(공학사)
2025년 3월~현재 :
한국과학기술원(KAIST)
산업및시스템공학과
관심분야 : Statistical Machine
Learning, Data Privacy

홍 정 희 (Ellen J. Hong)



2013년 2월 : KAIST
전기및전자공학과(공학박사)
2016년 10월~2018년 1월 :
동서대학교 컴퓨터공학부 조교수
2018년 2월~2019년 8월 : KT
융합기술원 선임연구원

2019년 9월~현재 : 연세대학교 소프트웨어학부 조교수
관심분야 : 인공지능, 시스템 모델링 시뮬레이션,
시뮬레이션 기반 최적화, 디지털 트윈, 지능형 시스템